

# 低秩矩阵完整化问题的几种高效解法

林陈冉

中国科学院大学

2016年12月19日

# 什么是低秩矩阵完整化

简单来说, 低秩矩阵完整化问题, 就是在仅仅知道矩阵的少部分元素的情况下, 恢复出这个矩阵的所有元素. 这个问题在统计, 图像处理, 计算几何, 机器学习, 信号处理, 模型控制等方面有广泛应用, 比如著名的NetFlix大奖赛问题.

# 数学模型

通常我们认为矩阵的秩比较小. 也就是这样的一个最优化问题:

$$\begin{aligned} \min \quad & \text{rank}(X) \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \forall (i, j) \in \Omega \end{aligned} \quad (2.1)$$

其中  $X, M \in \mathbb{R}^{p \times q}$ ,  $\Omega$  是已知元素的下标  $(i, j)$  构成的集合,  $|\Omega| = m$ .

在一些情况下, (2.1)等价于线性约束问题:

$$\begin{aligned} \min \quad & \text{rank}(X) \\ \text{s.t.} \quad & \mathcal{A}(X) = b \end{aligned} \quad (2.2)$$

其中  $b \in \mathbb{R}^m$ ,  $\mathcal{A}: \mathbb{R}^{p \times q} \rightarrow \mathbb{R}^m$  是线性算子.

# 数学模型

但是(2.1), (2.2)都是“**NP-难**”的, 因此需要一定的转化. 这里我们用核范数来近似矩阵的秩, 把(2.1)与(2.2)转化为以下形式:

$$\begin{aligned} \min \quad & \|X\|_* \\ \text{s.t.} \quad & \mathcal{A}(X) = b \end{aligned} \tag{2.3}$$

$$\begin{aligned} \min \quad & \|X\|_* \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \forall (i, j) \in \Omega \end{aligned} \tag{2.4}$$

# 数学模型

很自然的, 一个重要的问题是: (2.1)与(2.3), 或者(2.2)与(2.4)什么时候等价? 略过证明, 直接描述以下重要的结论:

- ▶ 对于(2.3), 当在某些正则条件下, 若已知元素个数  $|\Omega| = m = O(nr \cdot \text{polylog}(n))$ , 其中  $n = \max(p, q)$ ,  $\text{polylog}$  是多重对数函数, 则矩阵有很高概率可以恢复.
- ▶ 对于(2.4), 将线性映射  $\mathcal{A}$  的矩阵形式记作  $A$ , 当  $A$  是一个随机高斯矩阵, 若向量  $b$  的维数  $m \geq C(r(p+q)\log(pq))$ , 其中  $C$  是一个正的常数, 则矩阵有很高概率可以恢复.

# 数学模型

实际上, 由线性代数知识容易知道, (2.4)要求的线性约束条件并不总能成立, 因此有时需要适当松弛. 考虑(2.4)的罚函数:

$$\min \quad \|X\|_* + \frac{1}{2\mu} \|\mathcal{A}(X) - b\|_2^2 \quad (2.5)$$

其中  $\mu$  是某个给定常数.

下面, 将对(2.3), (2.4), (2.5)分别给出一种高效的解法.

# 问题转化

对于问题(2.3), 我们考虑它的对偶问题

$$\begin{aligned} \max_{y \in \mathbb{R}^m} \quad & b^\top y \\ \text{s.t.} \quad & \|\mathcal{A}^*(y)\|_2 \leq 1 \end{aligned} \tag{3.1}$$

引入一个形式上的变量  $S$ , 将(3.1)变为如下的等价形式

$$\begin{aligned} \min_{y \in \mathbb{R}^m} \quad & -b^\top y \\ \text{s.t.} \quad & \mathcal{A}^*(y) - S = 0 \\ & \|S\|_2 \leq 1 \end{aligned} \tag{3.2}$$

# 问题转化

可以考虑(3.2)的增广Lagrange函数

$$L(y, S, X, \mu) = -b^\top y + \langle X, \mathcal{A}^*(y) - S \rangle + \frac{1}{2\mu} \|\mathcal{A}^*(y) - S\|_F^2 \quad (3.3)$$

由此我们得到(3.1)的一个等价问题

$$\begin{aligned} \min_{y, S} \quad & L(y, S, X, \mu) \\ \text{s.t.} \quad & \|S\|_2 \leq 1 \end{aligned} \quad (3.4)$$

通过选取最佳的  $\mu$  和  $X$  可以求出(3.4)的最优解.



# 问题转化

对下面的几个量进行迭代, 可以求解问题(3.4)

$$\begin{aligned}\mu^{k+1} &= \alpha \mu^k, \quad \alpha \in (0, 1) \\ X^{k+1} &= X^k + \frac{\mathcal{A}^*(y^{k+1}) - S^{k+1}}{\mu^k} \\ (y^{k+1}, S^{k+1}) &= \arg \min_{y, S} L(y, S, X^k, \mu^k)\end{aligned}\tag{3.5}$$

# 交替方向法

但实际上, (3.5)第三式并不容易解, 因此我们考虑使用交替方向法来求解这个方程, 即固定  $S$  求  $y$ , 再固定  $y$  求  $S$ .

$$y^{k+1} = \arg \min_{y, S} L(y, S^k, X^k, \mu^k) \quad (3.6)$$

$$S^{k+1} = \arg \min_{y, S} L(y^{k+1}, S, X^k, \mu^k) \quad (3.7)$$

# 交替方向法

## 定理

当固定  $S^k$  , (3.6)的最优解为:

$$y^{k+1} = \mu^k(b - \mathcal{A}(X^k)) + \mathcal{A}(S^k) \quad (3.8)$$

当固定  $y^{k+1}$  , (3.7)的最优解为:

$$S^{k+1} = U \text{Diag}(\min\{\sigma, 1\}) V^\top \quad (3.9)$$

其中  $U, V$  来自  $Y = \mathcal{A}^*(y^{k+1}) + \mu^k X^k$  的奇异值分解, 即  $Y = U \text{Diag}(\sigma) V^\top$  .

# AAL法算法

## 算法

步1 给出  $\mu^0$ ,  $X^0$ ,  $y^0$ ,  $S^0$ ,  $\epsilon$ ,  $\alpha$ , 设置计数器  $k = 0$ ;

步2 若  $\frac{\|X^{k+1} - X^k\|_F}{\max\{1, \|X^k\|_F\}} \leq \epsilon$ , 则停止;

步3 计算  $y^{k+1} = \mu^k(b - \mathcal{A}(X^k)) + \mathcal{A}(S^k)$ ;

步4 计算  $Y = \mathcal{A}^*(y^{k+1}) + \mu^k X^k$ , 并计算其SVD:

$$Y = U \text{Diag}(\sigma) V^\top;$$

步5 计算  $S^{k+1} = U \text{Diag}(\min\{\sigma, 1\}) V^\top$ ;

步6 计算  $X^{k+1} = \frac{Y - S^{k+1}}{\mu^k}$ ;

步7 计算  $\mu^{k+1} = \alpha \mu^k$ ,  $k = k + 1$ , 转步2.

# SDP问题

对于问题(2.4), 我们可以考虑把它转化为一个半定规划(SDP)问题.

一个标准的半定规划问题是

$$\begin{aligned} \min_{X \in S^n} \quad & \langle C, X \rangle \\ \text{s.t.} \quad & \mathcal{A}(X) = b, X \succ 0 \end{aligned} \tag{4.1}$$

其中  $b \in \mathbb{R}^m$ ,  $\mathcal{A}(X) = (\langle A_1, X \rangle, \dots, \langle A_m, X \rangle)$ ,  $C, A_i \in S^n$ ,  $S^n$  是全体对称矩阵.

# Schur补

## 定义

对于一个对称正定矩阵  $X \in S^n$  , 我们可以把它写成分块矩阵的形式

$$X = \begin{pmatrix} \xi & y^\top \\ y & B \end{pmatrix} = \begin{pmatrix} 1 & y^\top B^{-1} \\ 0 & I \end{pmatrix} \begin{pmatrix} \xi - y^\top B^{-1}y & 0 \\ 0 & B \end{pmatrix} \begin{pmatrix} 1 & 0 \\ B^{-1}y & I \end{pmatrix} \quad (4.2)$$

$(X/B) = \xi - y^\top B^{-1}y$  , 称为 $X$ 对于 $B$ 的Schur补, 具有性质

$$X \succeq 0 \Leftrightarrow B \succeq 0, (X/B) \geq 0 \quad (4.3)$$

# SOCP问题

约定以下记号

$$X_{\alpha, \beta} = \begin{cases} x_{\alpha\beta} & \alpha, \beta \in \mathbb{R} \\ (x_{\alpha\beta_1}, \dots, x_{\alpha\beta_n}) & \alpha \in \mathbb{R}, \beta = \{\beta_1, \dots, \beta_n\} \\ (x_{\alpha_1\beta}, \dots, x_{\alpha_m\beta})^\top & \alpha = \{\alpha_1, \dots, \alpha_m\}, \beta \in \mathbb{R} \\ \begin{pmatrix} x_{\alpha_1\beta_1} & \cdots & x_{\alpha_1\beta_n} \\ \cdots & \cdots & \cdots \\ x_{\alpha_m\beta_1} & \cdots & x_{\alpha_m\beta_n} \end{pmatrix} & \alpha = \{\alpha_1, \dots, \alpha_m\}, \beta = \{\beta_1, \dots, \beta_n\} \end{cases} \quad (4.4)$$

$$i^c = \{1, \dots, n\} \setminus \{i\} = \{1, \dots, i-1, i+1, \dots, n\} \quad (4.5)$$

# SOCP问题

令  $X = \begin{pmatrix} \xi & y^\top \\ y & B \end{pmatrix} = \begin{pmatrix} X_{i,i} & X_{i,i^c} \\ X_{i^c,i} & X_{i^c,i^c} \end{pmatrix}$ , 等号在相差一个初等变化下成立. 基于Schur补, 令  $i$  取遍  $\{1, \dots, n\}$ , 逐行解如下的SOCP问题来解决SDP问题(4.1)

$$\begin{aligned} \min_{[\xi; y] \in \mathbb{R}^n} \quad & \bar{c}^\top \begin{pmatrix} \xi \\ y \end{pmatrix} \\ \text{s.t.} \quad & \bar{X} \begin{pmatrix} \xi \\ y \end{pmatrix} = \bar{b} \\ & (X/B) \geq \delta \end{aligned} \tag{4.6}$$



# SOCP问题

其中

$$\bar{c} = \begin{pmatrix} C_{i,i} \\ 2C^{i^c,i} \end{pmatrix}, \bar{X} = \begin{pmatrix} X^{(1)}_{i,i} & 2X^{(1)}_{i,i^c} \\ \dots & \dots \\ X^{(m)}_{i,i} & X^{(m)}_{i,i^c} \end{pmatrix}, \bar{b} = \begin{pmatrix} b_1 - \langle X^{(1)}_{i^c,i^c}, B \rangle \\ \dots \\ b_m - \langle X^{(m)}_{i^c,i^c}, B \rangle \end{pmatrix} \quad (4.7)$$

若  $X$  是半正定的, 即  $X \succeq 0$ , 取  $\delta = 0$ ;

若  $X$  是正定的, 即  $X \succ 0$ , 用大于零的数来限制Schur补, 取  $\delta > 0$ .

# Powell罚函数

考虑(3.7)的Powell罚函数

$$F(X, \theta, \mu) = \bar{c}^\top \begin{pmatrix} \xi \\ y \end{pmatrix} + \frac{1}{2\mu} \|\bar{X}[\xi; y] - \bar{b} - \theta\|_2^2 \quad (4.8)$$

其中  $\theta \in \mathbb{R}^m$ ,  $\mu > 0$  都是给定的. 记  $\lambda = \theta + \bar{b}$

(4.6)等价于以下问题

$$\begin{aligned} \min_X \quad & F(X, \lambda, \mu) = \bar{c}^\top \begin{pmatrix} \xi \\ y \end{pmatrix} + \frac{1}{2\mu} \|\bar{X}[\xi; y] - \lambda\|_2^2 \\ \text{s.t.} \quad & X \succeq 0 \end{aligned} \quad (4.9)$$

# 用SDP和RBR法补全矩阵

回头考虑(2.4), 我们需要把它转化为一个SDP问题(4.1), 考虑两种情况:

- ▶ 当  $X \in S^n$ ,  $\|X\|_* = \text{tr}(X)$ , (2.4)等价于下面的SDP问题

$$\begin{aligned} \min_X \quad & \text{tr}(X) = \langle E, X \rangle \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \quad \forall (i, j) \in \Omega \end{aligned} \tag{4.10}$$

# 用SDP和RBR法补全矩阵

- 当  $X \in \mathbb{R}^{p \times q}$  不是对称正定的, 可以考虑一个更大的对称正定矩阵  $W$ . 当补全了  $W$ , 则  $X$  自然被补全了

$$\begin{aligned} \min_X \quad & tr(X) \\ \text{s.t.} \quad & X = \begin{pmatrix} X_1 & W \\ W^\top & X_2 \end{pmatrix} \succ 0 \\ & W_{ij} = M_{ij}, \quad \forall (i, j) \in \Omega \end{aligned} \quad (4.11)$$

其中  $X \in S^n$ ,  $n = p + q$ ,  $W_1 \in S^p$ ,  $W_2 \in S^q$ ,  $X, W_1, W_2 \succ \delta$ .

# 用SDP和RBR法补全矩阵

我们主要讨论一般的情况, 即问题(4.11). 对于某个  $i$ , 我们把向量  $y$  分为两个部分, 即

$$y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}, \quad y_1 = X_{\alpha_i, i}, \quad y_2 = X_{\beta_i, i} \quad (4.12)$$

其中  $\alpha_i = \begin{cases} \{j + p | (i, j \in \Omega)\}, i \leq p \\ \{j | (j, i - p) \in \Omega\}, p < i \leq n \end{cases}$ ,  $\beta_i = \{1, \dots, p\} \setminus (\alpha_i \cup \{i\})$ ,  $y_1$

是  $X$  第  $i$  列除去第  $i$  行后所有已知元素构成的列向量,  $y_2$  是  $X$  第  $i$  列除去第  $i$  行后所有未知元素构成的列向量.

# 用SDP和RBR法补全矩阵

分解这个对称正定矩阵  $X$ ，使其符合SOCP问题(4.6)的形式，令

$$B = \begin{pmatrix} X_{\alpha_i, \alpha_i} & X_{\alpha_i, \beta_i} \\ X_{\beta_i, \alpha_i} & X_{\beta_i, \beta_i} \end{pmatrix}, \quad \xi = X_{i,i}.$$

对照SOCP问题的罚函数形式(4.9)，可以给出  $\bar{X} \begin{pmatrix} \xi \\ y \end{pmatrix}$ ,  $\lambda$  和  $\bar{c}$  的显式表达

$$\lambda = \begin{cases} (M_{i, \alpha_i - p})^\top, & i \leq p \\ M_{\alpha_i, i-p}, & p < i \leq n \end{cases}, \quad \bar{X} \begin{pmatrix} \xi \\ y \end{pmatrix} = y_1, \quad \bar{c} = (1, \overbrace{0, \dots, 0}^{n-1}) \quad (4.13)$$

# 用SDP和RBR法补全矩阵

故(4.9)化为以下的形式

$$\begin{aligned} \min \quad & \xi + \frac{1}{2\mu} \|y_1 - \lambda\|_2^2 \\ \text{s.t.} \quad & \xi - y^\top B^{-1} y \geq \delta \end{aligned} \quad (4.14)$$

现在只需要解这个问题的最优解, 即可得到矩阵  $X$  的第  $i$  行和第  $i$  列, 当  $i$  循环取遍 1 到  $n$ , 就可以得到原问题(4.11)的最优解, 从而求得目标矩阵  $W$ .

# 用SDP和RBR法补全矩阵

## 定理

问题(4.14)的最优解为

$$\begin{aligned} y_1 &= (2\mu I + X_{\alpha,\alpha})^{-1} X_{\alpha,\alpha} \tilde{b} \\ y_2 &= \frac{1}{2\mu} X_{\beta,\alpha} (\lambda - y_1) \\ \xi &= \frac{1}{2\mu} y_1^\top (\lambda - y_1) + \delta \end{aligned} \quad (4.15)$$



# RBR算法

## 算法

- 步1 给出  $\delta \geq 0$ ,  $X^1 \succ 0$ ,  $F^0 = \text{tr}(X^1)$ ,  $F^1 = +\infty$ ,  $\epsilon > 0$ , 设置计数器  $k = 1$ ,  $i = 1$ ;
- 步2 若  $\frac{|F^{k-1} - F^k|}{\max\{1, |F^{k-1}|\}} \leq \epsilon$ , 则停止;
- 步3 若  $i > n$ , 则令  $i = 1$ ,  $X^{k+1} = X^k$ ,  $k = k + 1$ ,  $F^k = \text{tr}(X^k)$ , 转步2;
- 步4 求出  $i$  对应的  $\alpha_i$ ,  $\beta_i$ ;
- 步5 若  $|\alpha_i| = 0$ , 令  $X_{\alpha, \alpha}^k = x_{\alpha, \beta}^l = X_{\beta, \alpha}^k = 0$ ,  $X_{\beta, \beta}^k = X^k$ , 否则按通常定义求出以上几个量.
- 步6 按(4.15), 计算当前最优解  $\xi$ ,  $y_1$ ,  $y_2$ , 以及  $y = [y_1, y_2]$ ;
- 步7 令  $X_{i, i}^k = \xi$ ,  $X_{i, i^c}^k = y$ ,  $X_{i^c, i}^k = y^\top$ ;
- 步8  $i = i + 1$ , 转步3;

# FPC法

FPC法是一种基于不动点定理的算法, 可以解决问题(2.5).

$\|X\|_* + \frac{1}{2\mu}\|\mathcal{A}(X) - b\|_2^2$  是一个凸函数, 求最优解只要求梯度为0的点. 但  $\|X\|_*$  是不可微的, 故考虑次梯度

$$0 \in \mu\partial\|X\|_* + g(X) \quad (5.1)$$

其中  $g(X) = \mathcal{A}^*(\mathcal{A}(X) - b)$

设  $Y = X - \psi g(X)$ ,  $\psi > 0$  是给定常数, 则(5.1)等价于

$$0 \in \psi\mu\partial\|X\|_* + X - (X - \psi g(X)) = \psi\mu\partial\|X\|_* + X - Y \quad (5.2)$$

# FPC法

(5.2)恰好是  $\|X\|_* + \frac{1}{2}\|X - Y\|_F^2$  的次梯度, 即(2.4)等价于

$$\min \psi \mu \|X\|_* + \frac{1}{2} \|X - Y\|_F^2 \quad (5.3)$$

## 定义

对  $X \in \mathbb{R}^{m \times n}$  做奇异值分解,  $X = U \text{Diag}(\sigma) V^\top$ ,  $r = \text{rank}(X)$ ,  $U \in \mathbb{R}^{m \times r}$ ,  $V \in \mathbb{R}^{n \times r}$ , 对  $\forall \nu > 0$ , 定义向量  $\bar{\sigma} = (\bar{\sigma}_1, \dots, \bar{\sigma}_r)$ , 其中  $\bar{\sigma}_i = \max\{\sigma_i - \nu, 0\}$ .

*Shrinkage*算子  $S_\nu : \mathcal{R}^{m \times n} \rightarrow \mathcal{R}^{m \times n}$ ,  $S_\nu(X) = U \text{Diag}(\bar{\sigma}) V^\top$

# FPC法

## 定理

问题(5.3)中, 当给定  $Y \in \mathcal{R}^{m \times n}$ , 最优解为  $S_{\psi_{\mu}}(Y)$ , 其中  $S_{\psi_{\mu}}(\cdot)$  是Shinkage算子

# FPC法的收敛性

上面的定理告诉我们, 只要求出合适的  $Y$ ,  $S_{\psi\mu}(Y)$  就是(2.5)的解.

由  $X$  与  $Y$  的关系可以看出, 若  $X^*$  是(2.5)的解, 则

$$X^* = S_{\psi\mu}(X^* - \mu g(X^*)) = S_{\psi\mu}(X^* - \mu \mathcal{A}^*(\mathcal{A}(X^*) - b)) \quad (5.4)$$

即  $X^*$  是映射  $S_{\psi\mu} \circ h$  的不动点, 其中  $h(X) = X - \mu g(X)$ . 我们有如下的结论.

# FPC法的收敛性

## 定理

*Shinkage*算子  $S_\nu(\cdot)$  是非扩张的, 即

$$\|S_\nu(Y_1) - S_\nu(Y_2)\|_F \leq \|Y_1 - Y_2\|_F \quad (5.5)$$

## 定理

当  $\mu \in (0, 2/\lambda_{\max}(A^\top A))$ , 其中  $A$  满足  $\mathcal{A}(X) = \text{Avec}(X)$ ,  $h$  是非扩张的, 即

$$\|h(X_1) - h(X_2)\|_F \leq \|X_1 - X_2\|_F \quad (5.6)$$

# FPC法的收敛性

自然的推论是, 当  $\mu \in (0, 2/\lambda_{\max}(A^\top A))$

$$\|S_{\psi_\mu}(h(X_1)) - S_{\psi_\mu}(h(X_2))\|_F \leq \|h(X_1) - h(X_2)\|_F \leq \|X_1 - X_2\|_F \quad (5.7)$$

即  $S_{\psi_\mu} \circ h$  是一个非扩张的映射, 由Brouwer不动点定理可知, 由任意  $X$  开始进行迭代, 都能收敛到某个不动点.

# 优化奇异值计算

实际计算中, 上述迭代过程中, 每步都要求做奇异值分解, 这并不是一件容易的事. 我们认为问题(2.5)中的原矩阵  $X$  是一个低秩矩阵, 那么其奇异值大多都是 0, 故可以考虑只求很少的几个奇异值.

这种优化FPC法中奇异值计算的方法, 就是FPCA法.



# 优化奇异值计算

$A \in \mathbb{R}^{p \times q}$ , 取整数  $c, d, 1 \leq d \leq c \leq q$ ,  $(P_1, \dots, P_q)$ ,  $P_i \geq 0$ ,  $\sum_{i=1}^q P_i = 1$ . 构造随机向量  $(i_1, \dots, i_c)$ ,  $P(i_t = j) = P_j$ ,  $t \in \{1, \dots, c\}$ ,  $j \in \{1, \dots, q\}$ . 再令随机矩阵

$$C = \begin{pmatrix} C^{(1)} \\ \dots \\ C^{(c)} \end{pmatrix} = \begin{pmatrix} A^{(i_1)} / \sqrt{cP_{i_1}} \\ \dots \\ A^{(i_c)} / \sqrt{cP_{i_c}} \end{pmatrix} \in \mathbb{R}^{p \times c} \quad (5.8)$$

# 优化奇异值计算

求  $C^T C$  的特征值分解

$$C^T C = \sum_{i=1}^c \sigma_i^2(C) y_i y_i^T \quad (5.9)$$

其中  $\sigma_i(C) \geq 0$ ，为  $C$  的奇异值，再构造矩阵

$$H = \begin{pmatrix} H^{(1)} \\ \dots \\ H^{(d)} \end{pmatrix} = \begin{pmatrix} C y_1 / \sigma_1(C) \\ \dots \\ C y_d / \sigma_d(C) \end{pmatrix} \in \mathbb{R}^{p \times d} \quad (5.10)$$

# 优化奇异值计算

令

$$A_d = H \text{Diag}(\sigma(C)) (A^\top H \text{Diag}(1/\sigma(C)))^\top \quad (5.11)$$

可以证明  $A_d$  是  $A$  的一个比较好的近似

$$\|A - A_d\|_\xi^2 \leq \min_{\text{rank}(D) \leq d} \|A - D\|_\xi^2 + \text{polylog}(d, 1/c) \|A\|_\xi^2 \quad (5.12)$$

其中  $\xi = 2$  或  $F$ ,  $\text{polylog}$  是多重对数函数.

# FPCA算法

## 算法

步1 给出  $X^1$ ,  $\mu^0 > 0$ ,  $1 > \theta > 0$ ,  $\epsilon > 0$ , 设置计数器  $k = 1$ ;

步2 若  $\mu^k = \mu^{k-1}\theta \leq \epsilon$ , 则停止;

步3 选取合适的  $\psi > 0$ ;

步4 计算  $Y^k = X^k - \psi \mathcal{A}^*(\mathcal{A}(X^k) - b)$ ;

步5 选取合适的  $d$ ,  $\{P_i\}$ , 按(5.8)至(5.11), 计算近似的奇异值分解  $Y_d = H \text{Diag}(\sigma(C)) (Y^\top H \text{Diag}(1/\sigma(C)))^\top$

步6 计算  $X^{k+1} = S_{\psi\mu^k}(Y_d)$ ;

步7  $k = k + 1$ , 转步2;

*Thank you!*