

# 低秩矩阵完整化问题的几种高效解法

林陈冉

2017年1月1日

**摘要** 本文是在阅读 *Solving Low-Rank Matrix Completion Problems Efficiently*<sup>[3]</sup> 后所写的读书报告. 文章大部分内容依照原文翻译, 有些是查阅其他文献所得, 也加入了一些自己的理解和证明. 文章首先提出了低秩矩阵完整化的几个数学模型, 再对其中三个模型分别提出了一种较为高效的算法, 分别是ADAL法, RBR法和FPCA法. 第一种算法ADAL法, 是考虑原问题的对偶问题, 再用增广拉格朗日函数, 采用交替方向法求解. 第二种算法RBR法, 是基于半定规划, 采用逐行求解不断迭代的方式. 第三种算法FPCA法, 主要是对FPC法的奇异值计算的过程进行了优化, 通过求一个低秩的矩阵的奇异值分解来近似分解整个原矩阵.

## 1 简介

### 1.1 什么是低秩矩阵完整化

简单来说, 低秩矩阵完整化问题, 就是在仅仅知道矩阵的少部分元素的情况下, 恢复出这个矩阵的所有元素. 显而易见, 补全一个完全随机的矩阵几乎是不可能的, 也是意义不大的. 一般情况下, 我们认为所需要补全的矩阵是有一定规律的, 也就是说, 这个矩阵的秩比较小. 这个问题在统计, 图像处理, 计算几何, 机器学习, 信号处理, 模型控制等方面有广泛应用, 比如著名的NetFlix大奖赛问题.

### 1.2 数学模型

通常我们最感兴趣的是这样的一个最优化问题:

$$\begin{aligned} \min \quad & \text{rank}(X) \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \forall (i, j) \in \Omega \end{aligned} \tag{1.1}$$

其中  $X, M \in \mathbb{R}^{p \times q}$ ,  $\Omega$  是已知元素的下标  $(i, j)$  构成的集合,  $|\Omega| = m$ .

(1.1)是下面的问题的特殊情况:

$$\begin{aligned} \min \quad & \text{rank}(X) \\ \text{s.t.} \quad & \mathcal{A}(X) = b \end{aligned} \tag{1.2}$$

其中  $b = (b_1, \dots, b_m) \in \mathbb{R}^m$ ,  $\mathcal{A}: \mathbb{R}^{p \times q} \rightarrow \mathbb{R}^m$  是线性算子.

但是(1.1), (1.2)都是"NP-难"的<sup>[7]</sup>, 因此需要一定的转化. 这里我们用核范数来近似矩阵的秩, 把(1.1)与(1.2)转化为以下形式:

$$\begin{aligned} \min \quad & \|X\|_* \\ \text{s.t.} \quad & \mathcal{A}(X) = b \end{aligned} \quad (1.3)$$

$$\begin{aligned} \min \quad & \|X\|_* \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \forall (i, j) \in \Omega \end{aligned} \quad (1.4)$$

很自然的, 一个重要的问题是: (1.1)与(1.3), 或者(1.2)与(1.4)什么时候等价? 略过证明, 直接描述以下重要的结论:

对于(1.3), Candes和陶哲轩等给出了一个证明. 当满足某些正则条件, 若已知元素个数  $|\Omega| = m = O(nr \cdot \text{polylog}(n))$ , 其中  $n = \max\{p, q\}$ ,  $\text{polylog}$  是多重对数函数, 则矩阵有很高概率可以通过(1.3)恢复.<sup>[1]</sup>

对于(1.4), Recht等给出了一个证明. 将线性映射  $\mathcal{A}$  的矩阵形式记作  $A$ , 即  $\mathcal{A}(X) = \text{Avec}(X)$ , 其中  $\text{vec}(X) \in \mathbb{R}^{pq}$  为矩阵  $X$  的向量化. 当  $A$  是一个随机高斯矩阵, 若向量  $b$  的维数  $m = O(r(p+q)\log(pq))$ , 则矩阵有很高概率可以通过(1.4)恢复.<sup>[8]</sup>

实际上, 由线性代数知识容易知道, (1.4)要求的线性约束条件并不总能成立, 因此有时需要适当松弛. 考虑(1.4)的罚函数:

$$\min \quad \|X\|_* + \frac{1}{2\mu} \|\mathcal{A}(X) - b\|_2^2 \quad (1.5)$$

其中  $\mu$  是某个给定常数.

本文主要将对(1.3), (1.4), (1.5)分别给出一种高效的解法.

## 1.3 一些自己的理解

### 1.3.1 $\mathcal{A}$ 与 $\mathcal{A}^*$

我们可以考虑下(1.2)中给出的线性算子  $\mathcal{A}$  到底是什么.  $\mathcal{A}: \mathbb{R}^{p \times q} \rightarrow \mathbb{R}^m$  可以看作  $m$  个线性算子的组合, 即  $\mathcal{A}(X) = (\mathcal{A}_1(X), \dots, \mathcal{A}_m(X))$ ,  $(\mathcal{A}_i: \mathbb{R}^{p \times q} \rightarrow \mathbb{R}) \in (\mathbb{R}^{p \times q})^*$ ,  $i = 1, \dots, m$ .

赋予矩阵内积后,  $\mathbb{R}^{p \times q}$  可以看作Hilbert的,  $(\mathbb{R}^{p \times q})^* = \mathbb{R}^{p \times q}$ . 由Ries表示定理,  $\exists A_i \in \mathbb{R}^{p \times q}$ , s.t.  $\mathcal{A}_i(X) = \langle A_i, X \rangle$ , 则  $\mathcal{A}(X) = (\langle A_1, X \rangle, \dots, \langle A_m, X \rangle)$ . 这说明从  $\mathbb{R}^{p \times q}$  到  $\mathbb{R}^m$  的线性映射实质上就是  $m$  个属于  $\mathbb{R}^{p \times q}$  的矩阵.

我们还可以考虑  $\mathcal{A}^*$ , 显然  $\mathcal{A}^*: \mathbb{R}^m \rightarrow \mathbb{R}^{p \times q}$ .

$$\langle \mathcal{A}(X), y \rangle = \langle (\langle A_i, X \rangle), (y_i) \rangle = \sum_{i=1}^m y_i \langle A_i, X \rangle = \langle X, \sum_{i=1}^m y_i A_i \rangle = \langle X, \mathcal{A}^*(y) \rangle$$

故  $\mathcal{A}^*(y) = \sum_{i=1}^m y_i A_i$ .

### 1.3.2 核范数与秩

大部分文献中, 都是直接使用核范数来近似秩, 并未说明为什么. 实际上,  $\|A\|_* = \|\sigma(A)\|_1$ ,  $\text{rank } A = \|\sigma(A)\|_0$ , 由此可以看出, 核范数与秩的关系, 即1-范数与0-范数的关系, 故用核范数来近似秩.

## 2 预备知识

### 2.1 矩阵范数

以下默认  $A \in \mathbb{R}^{m \times n}$ ,  $x \in \mathbb{R}^n$ ,  $k = \max\{m, n\}$ ,  $\sigma(A) = (\sigma_1(A), \dots, \sigma_k(A)) \in \mathbb{R}^k$  是矩阵  $A$  的奇异值向量,  $\sigma_i(A)$  是矩阵  $A$  的第  $i$  个奇异值.

#### 2.1.1 Schatten-p范数

矩阵的Schatten-p范数是矩阵奇异值向量的p-范数<sup>[9]</sup>

$$\|A\|_{S_p} = \left( \sum_i^k \sigma_i(A)^p \right)^{\frac{1}{p}} = \|\sigma(A)\|_p$$

#### 2.1.2 诱导-p范数

矩阵的诱导-p范数<sup>[6]</sup>是将矩阵看作线性算子, 由向量的p-范数诱导而来

$$\|A\|_p = \sup_{\|x\|_p \leq 1} \|Ax\|_p$$

常见的有2-范数, 又称谱范数:

$$\|A\|_2 = \max_i \sigma_i(A)$$

实际上2-范数也是  $p = \infty$  时的Schatten-p范数.

1-范数, 又称列范数:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

$\infty$ -范数, 又称行范数:

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

### 2.1.3 核范数

矩阵的核范数, 又称迹范数, 是在  $p = 1$  时的Schatten-p范数<sup>[6]</sup>

$$\|A\|_* = \sum_i^k \sigma_i(X) = \text{tr}(\sqrt{AA^\top}) = \|A\|_{\text{tr}}$$

特别的, 当  $A$  是对称正定的方阵, 则有  $A = \sqrt{AA^\top}$ , 即

$$\|A\|_* = \text{tr}(A)$$

### 2.1.4 F-范数

矩阵的F-范数定义类似于向量的2-范数<sup>[6]</sup>

$$\|A\|_F = \left( \sum_{i,j} a_{ij}^2 \right)^{\frac{1}{2}}$$

定义矩阵内积  $\langle A, X \rangle = \text{tr}(A^\top X)$ , F-范数与矩阵内积是相容的, 即  $\|A\|_F = \langle A, A \rangle^{\frac{1}{2}}$ , 可以看作内积诱导的范数. F-范数也是  $p = 2$  时的Schatten-p范数.

## 2.2 罚函数

对于约束优化问题:

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, \quad i = 1, \dots, m_e; \\ & c_i(x) \geq 0, \quad i = m_e + 1, \dots, m \end{aligned} \quad (2.1)$$

我们可以通过把约束条件平方后, 乘上一个很大的常数  $\mu$ , 再加入到目标函数上, 转化为罚函数<sup>[12]</sup>

$$P(x, \mu) = f(x) + \mu \|\bar{c}(x)\|_2^2 \quad (2.2)$$

其中  $\bar{c}(x) = (\bar{c}_1(x), \dots, \bar{c}_m(x)) \in \mathbb{R}^m$ ,  $\bar{c}_i(x)$  如下定义:  $\bar{c}_i(x) = \begin{cases} c_i(x), & i \leq m_e \\ \max\{0, c_i(x)\}, & i > m_e \end{cases}$ .

当  $\mu \rightarrow \infty$ , (2.3)和原问题(2.1)等价.

$$\min_x P(x, \mu) \quad (2.3)$$

但在实际中,  $\mu$  无法取到无穷大, 为了克服这一缺点, 可以定义增广Lagrange函数<sup>[12]</sup>(以下叙述仅考虑等值约束的情况, 即  $m_e = m$ ):

$$P(x, \lambda, \mu) = f(x) - \lambda^\top c(x) + \frac{1}{2}\mu \|c(x)\|_2^2 \quad (2.4)$$

其中  $\lambda, \lambda, \mu, c(x) \in \mathbb{R}^m$  给定.

(2.4)等价于以下的Powell罚函数<sup>[12]</sup>

$$P(x, \theta, \mu) = f(x) + \frac{1}{2}\mu \|c(x) - \theta\|_2^2 \quad (2.5)$$

其中  $c(x), \theta \in \mathbb{R}^m$ .

(2.3)与(2.5)只相差一个与  $x$  无关的常数  $\frac{1}{2}\mu \|\theta\|_2^2$ .<sup>[12]</sup>

## 2.3 对偶问题

对于约束优化问题(2.1),它的Langrange函数为

$$L(x, \mu, \lambda) = f(x) + \sum_{i=1}^{m_e} \mu_i c_i(x) + \sum_{i=m_e+1}^m \lambda_i c_i(x) \quad (2.6)$$

定义  $g(\mu, \lambda) = \min_x L(x, \mu, \lambda)$ , 通过这个函数我们可以把(2.1)转化为它的对偶问题<sup>[12]</sup>

$$\begin{aligned} \max_{\mu, \lambda} \quad & g(\mu, \lambda) \\ \text{s.t.} \quad & \mu \succeq 0 \end{aligned} \quad (2.7)$$

当满足一定条件(KKT条件)时, (2.7)和(2.1)是等价的.

## 2.4 次梯度

$f: E \rightarrow \mathbb{R}$  是一个定义在  $\mathbb{R}^n$  的凸子集  $E$  上的实值函数,则所有满足

$$f(y) - f(x) \geq u(y - x), \quad \forall y \in E \quad (2.8)$$

的向量  $u$  称为  $f$  在  $x$  点的次梯度, 所有这样的  $u$  构成的集合称为  $f$  在  $x$  点的次梯度集.<sup>[12]</sup>

次梯度集通常用  $\partial f(x)$  表示

$$\partial f(x) = \{u \in \mathbb{R}^m | f(y) - f(x) \geq u(y - x), \quad \forall y \in E\} \quad (2.9)$$

当函数在  $x$  点可微,  $\partial f(x) = \{f'(x)\}$ ; 当函数在  $x$  点不可微,  $\partial f(x)$  是一个非空的紧凸集.

对于不可微函数或者不可微点, 我们可以采用次梯度替代梯度进行分析. 众所周知, 一个点是最优解的必要条件是该点梯度为0. 相应的, 有如下结论:

**定理 2.1.**  $x^*$  是(2.1)问题的最优解的一个必要条件是:  $0 \in \partial f(x^*)$ . 特别的, 若  $f$  是凸函数, 则是充要条件.

特别指出, 核范数是非光滑函数的, 次梯度集如下<sup>[10]</sup>

$$\partial \|X\|_* = \{UV^\top + W | U^\top W = 0, WV = 0, \|W\|_2 \leq 1\} \quad (2.10)$$

其中  $X = UDV^\top$ .

### 3 交替方向增广Lagrange法

#### 3.1 问题转化

**命题 3.1.** 问题(1.3)的对偶问题是

$$\begin{aligned} \max_{y \in \mathbb{R}^m} \quad & b^\top y \\ \text{s.t.} \quad & \|\mathcal{A}^*(y)\|_2 \leq 1 \end{aligned} \quad (3.1)$$

这个结论被大多数文章认为是显然的, 这里给出一个我自己的证明.

**证明.** 问题(1.3)的拉格朗日函数为

$$L(x, y) = \|X\|_* - (\mathcal{A}(X) - b)^\top y \quad (3.2)$$

其中  $y \in \mathbb{R}^m$ . 由于  $\|X\|_*$  不光滑, 我们考虑(3.2)的次梯度集. 又(3.2)是凸函数, 函数在某点取到极值, 等价于 0 属于该点的次梯度集, 即

$$0 \in \partial \|X\|_* - \mathcal{A}^*(y)$$

这说明  $\exists W, \|W\|_2 \leq 1, \mathcal{A}^*(y) = UV^\top + W$ , 其中  $X = UDV^\top$ . 由  $\|W\|_2 \leq 1$  易知  $\|\mathcal{A}^*(y)\|_2 \leq 1$ .

由核范数次梯度的定义,  $U^\top \mathcal{A}^*(y) = V^\top$ ,  $\mathcal{A}^*(y)V = U$ , 即  $\mathcal{A}^*(y) = UV^\top$ , 那么可以知道

$$\begin{aligned}
 g(y) &= \min_x L(x, y) \\
 &= \|X\|_* - \mathcal{A}(X)^\top y + b^\top y \\
 &= \|UDV^\top\|_* - \langle UDV^\top, \mathcal{A}^*(y) \rangle + b^\top y \\
 &= \text{tr}(D) - \text{tr}(VD^\top U^\top UV^\top) + b^\top y \\
 &= b^\top y
 \end{aligned} \tag{3.3}$$

由此我们可以得到结论, 即(1.3)的对偶是(3.1).  $\square$

引入一个形式上的变量  $S$ , 将(3.1)变为如下的等价形式

$$\begin{aligned}
 \min_{y \in \mathbb{R}^m} \quad & -b^\top y \\
 \text{s.t.} \quad & \mathcal{A}^*(y) - S = 0 \\
 & \|S\|_2 \leq 1
 \end{aligned} \tag{3.4}$$

可以考虑(3.4)的增广Lagrange函数

$$L(y, S, X, \mu) = -b^\top y + \langle X, \mathcal{A}^*(y) - S \rangle + \frac{1}{2\mu} \|\mathcal{A}^*(y) - S\|_F^2 \tag{3.5}$$

其中  $X \in \mathbb{R}^{p \times q}$ ,  $\|\cdot\|_F$  是矩阵的  $F$ -范数.

由此我们得到(3.1)的一个等价问题

$$\begin{aligned}
 \min_{y, S} \quad & L(y, S, X, \mu) \\
 \text{s.t.} \quad & \|S\|_2 \leq 1
 \end{aligned} \tag{3.6}$$

通过选取最佳的  $\mu$  和  $X$  可以求出(3.6)的最优解.

采用如下的迭代过程以求解问题(3.6)

$$\begin{aligned}
 \mu^{k+1} &= \alpha \mu^k, \quad \alpha \in (0, 1) \\
 X^{k+1} &= X^k + \frac{\mathcal{A}^*(y^{k+1}) - S^{k+1}}{\mu^k} \\
 (y^{k+1}, S^{k+1}) &= \arg \min_{y, S} L(y, S, X^k, \mu^k)
 \end{aligned} \tag{3.7}$$

### 3.2 交替方向求解

但实际上, (3.7)第3式并不容易解, 因此我们考虑使用交替方向法来求解这个方程, 即

$$y^{k+1} = \arg \min_{y, S} L(y, S^k, X^k, \mu^k) \tag{3.8}$$

$$S^{k+1} = \arg \min_{y, S} L(y^{k+1}, S, X^k, \mu^k) \tag{3.9}$$

定理 3.1. 当固定  $S^k$ , (3.8)的最优解为:

$$y^{k+1} = \mu^k(b - \mathcal{A}(X^k)) + \mathcal{A}(S^k) \quad (3.10)$$

当固定  $y^{k+1}$ , (3.9)的最优解为:

$$S^{k+1} = U \text{Diag}(\min\{\sigma, 1\}) V^\top \quad (3.11)$$

其中  $U, V$  来自  $Y = \mathcal{A}^*(y^{k+1}) + \mu^k X^k$  的奇异值分解, 即  $Y = U \text{Diag}(\sigma) V^\top$ .

该结果是比较容易得到的, 文章中直接忽略了, 这里给出一个我自己的证明.

证明. 首先来求解(3.8), 当固定  $S^k$

$$L(y, S^k, X^k, \mu^k) = -b^\top y + \mathcal{A}(X^k)^\top y - \langle X, S^k \rangle + \frac{1}{2\mu^k} \|\mathcal{A}^*(y) - S^k\|_F^2 \quad (3.12)$$

记  $T = \mathcal{A}^*(y) - S^k$ ,  $\mathcal{A}_{ij} = (A_{1_{ij}}, \dots, A_{m_{ij}}) \in \mathbb{R}^m$ , 考虑  $\|T\|_F^2$

$$\|T\|_F^2 = \sum_{i,j} ((\sum_{k=1}^m y_k A_{k_{ij}}) - S_{ij}^k)^2 = \sum_{i,j} (\mathcal{A}_{ij}^\top y - S_{ij}^k)^2$$

则它对 $y$ 的梯度

$$\begin{aligned} \frac{\partial \|T\|_F^2}{\partial y} &= \frac{\partial \sum_{i,j} (\mathcal{A}_{ij}^\top y - S_{ij}^k)^2}{\partial y} \\ &= \sum_{i,j} \frac{\partial (\mathcal{A}_{ij}^\top y - S_{ij}^k)^2}{\partial y} \\ &= 2 \sum_{i,j} (\mathcal{A}_{ij}^\top y - S_{ij}^k) \mathcal{A}_{ij} \\ &= 2 (\sum_{i,j} T_{ij} A_{k_{ij}}) = 2 (\langle A_i, T \rangle) \\ &= 2 \mathcal{A}(\mathcal{A}^*(y) - S^k) \end{aligned} \quad (3.13)$$

由此可以给出(3.12)的梯度

$$\frac{\partial L(y, S^k, X^k, \mu^k)}{\partial y} = -b + \mathcal{A}(X^k) + \frac{1}{\mu^k} \mathcal{A}(\mathcal{A}^*(y) - S^k) \quad (3.14)$$

令(3.14)式等于0, 可得

$$y^{k+1} = \mu^k(b - \mathcal{A}(X^k)) + \mathcal{A}(S^k) \quad (3.15)$$

再考虑(3.9). 当固定  $y^{k+1}$

$$\begin{aligned} &L(y^{k+1}, S, X^k, \mu^k) \\ &= -b^\top y^{k+1} + \mathcal{A}(X^k)^\top y^{k+1} - \langle X, S \rangle + \frac{1}{2\mu^k} \|\mathcal{A}^*(y^{k+1}) - S\|_F^2 \\ &= \frac{1}{2\mu^k} (\|S\|_F^2 - 2\langle Y, S \rangle + \|\mathcal{A}^*(y^{k+1})\|_F^2) - b^\top y^{k+1} + \mathcal{A}(X^k)^\top y^{k+1} \end{aligned} \quad (3.16)$$



其中  $Y = \mathcal{A}^*(y^{k+1}) + \mu^k X^k$ .

$$\frac{\partial L(y^{k+1}, S, X^k, \mu^k)}{\partial S} = \frac{1}{2\mu^k} \left( \frac{\partial \|S\|_F^2}{\partial S} - 2 \frac{\partial \langle Y, S \rangle}{\partial S} \right) = \frac{S - Y}{\mu^k} \quad (3.17)$$

令(3.17)式等于0, 则可得  $S^{k+1} = Y$ , 但由约束条件  $\|S\|_2 \leq 1$ , 需对  $Y$  进行修正, 即

$$S^{k+1} = U \text{Diag}(\min\{\sigma, 1\}) V^\top \quad (3.18)$$

其中  $Y = U \text{Diag}(\sigma) V^\top$ . □

根据  $Y$  的定义, 可以简化  $X^{k+1}$  的计算方法

$$X^{k+1} = \frac{\mu^k X^k + \mathcal{A}^*(y^{k+1}) - S^{k+1}}{\mu^k} = \frac{Y - S^{k+1}}{\mu^k} \quad (3.19)$$

重复进行上述迭代, 到目标精度停止, 下面给出相应算法

#### 算法 1.

- 步1 给出  $\mu^0, X^0, y^0, S^0, \epsilon, \alpha$ , 设置计数器  $k = 0$ ;
- 步2 若  $\frac{\|X^{k+1} - X^k\|_F}{\max\{1, \|X^k\|_F\}} \leq \epsilon$ , 则停止;
- 步3 计算  $y^{k+1} = \mu^k (b - \mathcal{A}(X^k)) + \mathcal{A}(S^k)$ ;
- 步4 计算  $Y = \mathcal{A}^*(y^{k+1}) + \mu^k X^k$ , 并计算其SVD:  $Y = U \text{Diag}(\sigma) V^\top$ ;
- 步5 计算  $S^{k+1} = U \text{Diag}(\min\{\sigma, 1\}) V^\top$ ;
- 步6 计算  $X^{k+1} = \frac{Y - S^{k+1}}{\mu^k}$ ;
- 步7 计算  $\mu^{k+1} = \alpha \mu^k, k = k + 1$ , 转步2.

注 1. 本章除了两个自己证明的定理, 均为原文<sup>[9]</sup>的内容.

## 4 RBR法

### 4.1 SDP问题与Schur补

对于问题(1.4), 我们可以考虑把它转化为一个半定规划(SDP)问题.

一个标准的半定规划问题是

$$\begin{aligned} \min_{X \in S^n} \quad & \langle C, X \rangle \\ \text{s.t.} \quad & \mathcal{A}(X) = b, X \succ 0 \end{aligned} \quad (4.1)$$

其中  $b \in \mathbb{R}^m$ ,  $\mathcal{A}(X) = (\langle A^{(1)} X \rangle, \dots, \langle A^{(m)} X \rangle)$ ,  $C, A^{(i)} \in S^n$ ,  $S^n$  是全体对称矩阵.

对于一个对称正定矩阵  $X \in S^n$  , 我们可以把它写成分块矩阵的形式

$$X = \begin{pmatrix} \xi & y^\top \\ y & B \end{pmatrix} \quad (4.2)$$

其中  $\xi \in \mathbb{R}$  ,  $y \in \mathbb{R}^{n-1}$  ,  $B \in S^{n-1}$  .

容易验证的,  $X$  可以表示为以下形式

$$X = \begin{pmatrix} 1 & y^\top B^{-1} \\ 0 & I \end{pmatrix} \begin{pmatrix} \xi - y^\top B^{-1} y & 0 \\ 0 & B \end{pmatrix} \begin{pmatrix} 1 & 0 \\ B^{-1} y & I \end{pmatrix} \quad (4.3)$$

记  $(X/B) = \xi - y^\top B^{-1} y$  , 称为 $X$ 对于 $B$ 的Schur补.

显然的

$$X \succeq 0 \Leftrightarrow B \succeq 0, (X/B) \geq 0 \quad (4.4)$$

## 4.2 SOCP问题

约定以下记号

$$X_{\alpha, \beta} = \begin{cases} x_{\alpha\beta} & \alpha, \beta \in \mathbb{R} \\ (x_{\alpha\beta_1}, \dots, x_{\alpha\beta_n}) & \alpha \in \mathbb{R}, \beta = \{\beta_1, \dots, \beta_n\} \\ (x_{\alpha_1\beta}, \dots, x_{\alpha_m\beta})^\top & \alpha = \{\alpha_1, \dots, \alpha_m\}, \beta \in \mathbb{R} \\ \begin{pmatrix} x_{\alpha_1\beta_1} & \cdots & x_{\alpha_1\beta_n} \\ \cdots & \cdots & \cdots \\ x_{\alpha_m\beta_1} & \cdots & x_{\alpha_m\beta_n} \end{pmatrix} & \alpha = \{\alpha_1, \dots, \alpha_m\}, \beta = \{\beta_1, \dots, \beta_n\} \end{cases} \quad (4.5)$$

$$i^c = \{1, \dots, n\} \setminus \{i\} = \{1, \dots, i-1, i+1, \dots, n\} \quad (4.6)$$

令  $X = \begin{pmatrix} \xi & y^\top \\ y & B \end{pmatrix} = \begin{pmatrix} X_{i,i} & X_{i,i^c} \\ X_{i^c,i} & X_{i^c,i^c} \end{pmatrix}$ , 等号在相差一个初等变化下成立. 基于(4.4), 令  $i$  取遍  $\{1, \dots, n\}$  , 逐行解如下的SOCP问题来解决SDP问题(4.1)

$$\begin{aligned} \min_{[\xi; y] \in \mathbb{R}^n} \quad & \bar{c}^\top \begin{pmatrix} \xi \\ y \end{pmatrix} \\ \text{s.t.} \quad & \bar{A} \begin{pmatrix} \xi \\ y \end{pmatrix} = \bar{b} \\ & (X/B) \geq \delta \end{aligned} \quad (4.7)$$

其中

$$\bar{c} = \begin{pmatrix} C_{i,i} \\ 2C_{i^c,i} \end{pmatrix}, \quad \bar{A} = \begin{pmatrix} A_{i,i}^{(1)} & 2A_{i,i^c}^{(1)} \\ \dots & \dots \\ A_{i,i}^{(m)} & 2A_{i,i^c}^{(m)} \end{pmatrix}, \quad \bar{b} = \begin{pmatrix} b_1 - \langle A_{i^c,i^c}^{(1)}, B \rangle \\ \dots \\ b_m - \langle A_{i^c,i^c}^{(m)}, B \rangle \end{pmatrix} \quad (4.8)$$

若  $X$  是半正定的, 即  $X \succeq 0$ , 取  $\delta = 0$ ;

若  $X$  是正定的, 即  $X \succ 0$ , 用大于零的数来限制Schur补, 取  $\delta > 0$ .

考虑(4.7)的罚函数

$$F(X, \mu) = \bar{c}^\top \begin{pmatrix} \xi \\ y \end{pmatrix} + \frac{1}{2\mu} \|\bar{A}[\xi; y] - \bar{b}\|_2^2 \quad (4.9)$$

其中  $\mu > 0$  是给定的.

(4.7)等价于以下问题

$$\begin{aligned} \min_X \quad & F(X, \mu) \\ \text{s.t.} \quad & X \succeq 0 \end{aligned} \quad (4.10)$$

### 4.3 用SDP和RBR法补全矩阵

回头考虑(1.4). 当  $X \in S^n$  对称正定, 有  $\|X\|_* = \text{tr}(X)$ , (1.4)等价于下面的SDP问题

$$\begin{aligned} \min_X \quad & \text{tr}(X) = \langle E, X \rangle \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \quad \forall (i, j) \in \Omega \end{aligned} \quad (4.11)$$

当  $X \in \mathbb{R}^{p \times q}$  不是对称正定的, 可以考虑一个更大的对称正定矩阵  $W$ . 当补全了  $W$ , 则  $X$  自然被补全了(当然, 当  $X$  是对称正定矩阵时, 我们也可以这么做)

$$\begin{aligned} \min_X \quad & \text{tr}(X) \\ \text{s.t.} \quad & X = \begin{pmatrix} X_1 & W \\ W^\top & X_2 \end{pmatrix} \succ 0 \\ & W_{ij} = M_{ij}, \quad \forall (i, j) \in \Omega \end{aligned} \quad (4.12)$$

其中  $X \in S^n$ ,  $n = p + q$ ,  $W_1 \in S^p$ ,  $W_2 \in S^q$ ,  $X, W_1, W_2 \succ \delta$ .

我们主要讨论一般的情况, 即问题(4.12). 采用RBR法, 对于某个  $i$ , 我们把向量  $y$  分为两个部分, 即

$$y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}, \quad y_1 = X_{\alpha_i, i}, \quad y_2 = X_{\beta_i, i} \quad (4.13)$$

其中  $\alpha_i = \begin{cases} \{j + p | (i, j \in \Omega)\}, & i \leq p \\ \{j | (j, i - p) \in \Omega\}, & p < i \leq n \end{cases}$ ,  $\beta_i = \{1, \dots, p\} \setminus (\alpha_i \cup \{i\})$ ,  $y_1$  是  $X$  第  $i$  列除去第  $i$  行后所有已知元素构成的列向量,  $y_2$  是  $X$  第  $i$  列除去第  $i$  行后所有未知元素构成的列向量.

相应的,  $B = \begin{pmatrix} X_{\alpha_i, \alpha_i} & X_{\alpha_i, \beta_i} \\ X_{\beta_i, \alpha_i} & X_{\beta_i, \beta_i} \end{pmatrix}$ ,  $\xi = X_{i, i}$ . 同时, 可以给出  $\bar{A} \begin{pmatrix} \xi \\ y \end{pmatrix}$ ,  $\bar{b}$  和  $\bar{c}$  的显式表达

$$\bar{b} = \begin{cases} (M_{i, \alpha_i - p})^\top, & i \leq p \\ M_{\alpha_i, i - p}, & p < i \leq n \end{cases}, \quad \bar{A} \begin{pmatrix} \xi \\ y \end{pmatrix} = y_1, \quad \bar{c} = (1, \overbrace{0, \dots, 0}^{n-1}) \quad (4.14)$$

故(4.10)化为以下形式

$$\begin{aligned} \min \quad & \xi + \frac{1}{2\mu} \|y_1 - \bar{b}\|_2^2 \\ \text{s.t.} \quad & \xi - y^\top B^{-1} y \geq \delta \end{aligned} \quad (4.15)$$

**定理 4.1.** 问题(4.15)的最优解为

$$\begin{aligned} y_1 &= (2\mu I + X_{\alpha, \alpha})^{-1} X_{\alpha, \alpha} \\ y_2 &= \frac{1}{2\mu} X_{\beta, \alpha} (\bar{b} - y_1) \\ \xi &= \frac{1}{2\mu} y_1^\top (\bar{b} - y_1) + \delta \end{aligned} \quad (4.16)$$

**证明.** <sup>[11]</sup> 容易发现, 当  $\xi = y^\top B^{-1} y + \delta$  时, 才可能取到最小值, 则(4.15)等价于

$$\min_y y^\top B^{-1} y + \frac{1}{2\mu} \|y_1 - \bar{b}\|_2^2 \quad (4.17)$$

令其梯度为0

$$\begin{pmatrix} X_{\alpha, \alpha} & X_{\alpha, \beta} \\ X_{\beta, \alpha} & X_{\beta, \beta} \end{pmatrix}^{-1} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} + \frac{1}{2\mu} \begin{pmatrix} y_1 - \bar{b} \\ 0 \end{pmatrix} = 0 \quad (4.18)$$

变形可得

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} + \frac{1}{2\mu} \begin{pmatrix} X_{\alpha, \alpha} \\ X_{\beta, \alpha} \end{pmatrix} (y_1 - \bar{b}) = 0 \quad (4.19)$$

则

$$\begin{aligned} y_1 &= (2\mu I + X_{\alpha, \alpha})^{-1} X_{\alpha, \alpha} \\ y_2 &= \frac{1}{2\mu} X_{\beta, \alpha} (y_1 - \bar{b}) \end{aligned} \quad (4.20)$$

那么由(4.18)和(4.20), 有

$$\xi = y^\top B^{-1} y + \delta = -\frac{1}{2\mu} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}^\top \begin{pmatrix} y_1 - \bar{b} \\ 0 \end{pmatrix} + \delta = \frac{1}{2\mu} y_1^\top (\bar{b} - y_1) + \delta \quad (4.21)$$

即 (4.15)的最优解为(4.16) □

我们可以让  $i$  循环取遍  $\{1, \dots, n\}$ , 逐行求解(4.15), 最终解决问题(1.4). 给出算法

**算法 2.**

- 步1 给出  $\delta \geq 0$ ,  $X^1 \succ 0$ ,  $F^0 = \text{tr}(X^1)$ ,  $F^1 = +\infty$ ,  $\epsilon > 0$ , 设置计数器  $k = 1$ ,  $i = 1$ ;  
 步2 若  $\frac{|F^{k-1} - F^k|}{\max\{1, |F^{k-1}|\}} \leq \epsilon$ , 则停止;  
 步3 若  $i > n$ , 则令  $i = 1$ ,  $X^{k+1} = X^k$ ,  $k = k + 1$ ,  $F^k = \text{tr}(X^k)$ , 转步2;  
 步4 求出  $i$  对应的  $\alpha_i, \beta_i$ ;  
 步5 若  $|\alpha_i| = 0$ , 令  $X_{\alpha, \alpha}^k = X_{\alpha, \beta}^k = X_{\beta, \alpha}^k = 0$ ,  $X_{\beta, \beta}^k = X^k$ , 否则按通常定义求出以上几个量.  
 步6 按(4.16), 计算当前最优解  $\xi, y_1, y_2$ , 以及  $y = [y_1, y_2]$ ;  
 步7 令  $X_{i, i}^k = \xi$ ,  $X_{i, i^c}^k = y$ ,  $X_{i^c, i}^k = y^\top$ ;  
 步8  $i = i + 1$ , 转步3.

注 2. 本章除了已经标注引用的定理(4.1), 均为原文<sup>[9]</sup>的内容.

## 5 FPCA法

### 5.1 FPC法

FPC法是一种基于不动点定理的算法, 可以解决问题(1.5).

$\|X\|_* + \frac{1}{2\mu}\|\mathcal{A}(X) - b\|_2^2$  是一个凸函数, 求最优解只要求梯度为0的点. 但  $\|X\|_*$  是不可微的, 故考虑次梯度, 即

$$0 \in \mu \partial \|X\|_* + g(X) \quad (5.1)$$

其中  $g(X) = \mathcal{A}^*(\mathcal{A}(X) - b)$

设  $Y = X - \psi g(X)$ ,  $\psi > 0$  是给定常数, 则(5.1)等价于

$$0 \in \psi \mu \partial \|X\|_* + X - (X - \psi g(X)) = \psi \mu \partial \|X\|_* + X - Y \quad (5.2)$$

(5.2)恰好是  $\psi \mu \|X\|_* + \frac{1}{2}\|X - Y\|_F^2$  的次梯度, 即(1.4)等价于

$$\min \psi \mu \|X\|_* + \frac{1}{2}\|X - Y\|_F^2 \quad (5.3)$$

引入矩阵的Shrinkage算子<sup>[5]</sup>, 定义如下

**定义 5.1** (Shrinkage算子). 对  $X \in \mathbb{R}^{m \times n}$  做奇异值分解,  $X = U \text{Diag}(\sigma) V^\top$ ,  $r = \text{rank}(X)$ ,  $U \in \mathbb{R}^{m \times r}$ ,  $V \in \mathbb{R}^{n \times r}$ , 对  $\forall \nu > 0$ , 定义向量  $\bar{\sigma} = (\bar{\sigma}_1, \dots, \bar{\sigma}_r)$ , 其中  $\bar{\sigma}_i = \max\{\sigma_i - \nu, 0\}$ . Shrinkage算子  $S_\nu: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{m \times n}$ ,  $S_\nu(X) = U \text{Diag}(\bar{\sigma}) V^\top$

当认为(5.3)中的  $Y$  是给定的情况下, 有如下定理

**定理 5.1.** 问题(5.3)中, 当给定  $Y \in \mathcal{R}^{m \times n}$ , 最优解为  $S_{\psi\mu}(Y)$ , 其中  $S_{\psi\mu}(\cdot)$  是 *Shrinkage* 算子

**证明.** <sup>[5]</sup> 不失一般性, 设  $m \leq n$ , 记  $\nu = \psi\mu$ ,  $X = U\text{Diag}(\sigma)V^\top$ ,  $Y = U_Y\text{Diag}(\gamma)V_Y^\top$  是  $X, Y$  的SVD,  $\text{rank}X = r$ ,  $\text{rank}Y = t$ .

因为  $\partial\|X\|_* = \{UV^\top + W | U^\top W = 0, WV = 0, \|W\|_2 \leq 1\}$ , 找到矩阵  $\bar{U} \in \mathbb{R}^{m \times (m-r)}$ ,  $\bar{V} \in \mathbb{R}^{n \times (n-r)}$ , 使得  $\tilde{U} = [U, \bar{U}]$ ,  $\tilde{V} = [V, \bar{V}]$  分别是  $m, n$  阶正交矩阵. 那么易验证, 当  $\bar{\sigma} \in \mathbb{R}_+^{m-r}$ ,  $\|\bar{\sigma}\|_\infty \leq 1$ , 形如  $W = \bar{U}[\text{Diag}(\bar{\sigma}), 0]\bar{V}^\top$  的矩阵  $W \in \partial\|X\|_*$ .

若  $0 \in \nu\partial\|X\|_* + X - Y$ , 则说明  $\exists W \in \partial\|X\|_*$  使  $\nu(UV^\top + W) + X - Y = 0$ . 那么可以看到当  $W = \bar{U}[\text{Diag}(\bar{\sigma}), 0]\bar{V}^\top$ , 则要求

$$\begin{aligned} & \nu(UV^\top + W) + X - Y \\ &= (\nu UIV^\top + \bar{U}[\text{Diag}(\bar{\sigma}), 0]\bar{V}^\top + U\text{Diag}(\sigma)V^\top) - Y \\ &= \begin{pmatrix} U \\ \bar{U} \end{pmatrix} \left[ \begin{pmatrix} \nu I & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 \\ 0 & \nu\text{Diag}(\bar{\sigma}) & 0 \end{pmatrix} + \begin{pmatrix} \text{Diag}(\sigma) & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \right] \begin{pmatrix} V \\ \bar{V} \end{pmatrix}^\top - U_Y\text{Diag}(\gamma)V_Y^\top \\ &= \begin{pmatrix} U \\ \bar{U} \end{pmatrix} \begin{pmatrix} \nu I + \text{Diag}(\sigma) & 0 & 0 \\ 0 & \nu\text{Diag}(\bar{\sigma}) & 0 \end{pmatrix} \begin{pmatrix} V \\ \bar{V} \end{pmatrix}^\top - U_Y\text{Diag}(\gamma)V_Y^\top = 0 \end{aligned} \quad (5.4)$$

当  $\gamma_1 \geq \dots \geq \gamma_t \geq \nu$ , 那我们令  $X = S_\nu(Y)$ , 则  $r = t$ ,  $U = U_Y$ ,  $V = V_Y$ ,  $\sigma = (\gamma_1 - \nu, \dots, \gamma_t - \nu)$ , 对于这样的  $X$ , 取  $\bar{\sigma} = 0$  即  $W = 0$ , (5.4)成立.

当  $\gamma_1 \geq \dots \geq \gamma_k \geq \nu \geq \gamma_{k+1} \geq \dots \geq \gamma_t$ , 那我们令  $X = S_\nu(Y)$ , 则  $r = k$ ,  $\sigma = (\gamma_1 - \nu, \dots, \gamma_k - \nu, 0, \dots, 0)$ , 对这样的  $X$ , 取  $\bar{\sigma} = (\gamma_{k+1}/\nu, \dots, \gamma_t/\nu, 0, \dots, 0)$ , 同时令  $\bar{U}$  的前  $t - k$  行依次为  $U_Y$  的  $k + 1$  至  $t$  行,  $\bar{V}$  的前  $t - k$  行依次为  $V_Y$  的  $k + 1$  至  $t$  行, 即  $\begin{pmatrix} U \\ \bar{U} \end{pmatrix} = \begin{pmatrix} U_Y \\ \bar{U}' \end{pmatrix}$ ,  $\begin{pmatrix} V \\ \bar{V} \end{pmatrix} = \begin{pmatrix} V_Y \\ \bar{V}' \end{pmatrix}$ , 其中  $\bar{U}'$  是  $\bar{U}$  的后  $m - t$  行,  $\bar{V}'$  是  $\bar{V}$  的后  $n - t$  行, 此时(5.4)也成立.

故  $S_{\psi\mu}(Y)$  是(5.3)的解. □

## 5.2 FPC法的收敛性

也就是说, 我们只要求出合适的  $Y$ ,  $S_{\psi\mu}(Y)$  就是(1.5)的解. 由  $X$  与  $Y$  的关系可以看出, 若  $X^*$  是(1.5)的解, 则

$$X^* = S_{\psi\mu}(X^* - \mu g(X^*)) = S_{\psi\mu}(X^* - \mu \mathcal{A}^*(\mathcal{A}(X^*) - b)) \quad (5.5)$$

即  $X^*$  是映射  $S_{\psi\mu} \circ h$  的不动点, 其中  $h(X) = X - \mu g(X)$ .

我们有如下的结论

**定理 5.2.** *Shrinkage*算子  $S_\nu(\cdot)$  是非扩张的, 即

$$\|S_\nu(Y_1) - S_\nu(Y_2)\|_F \leq \|Y_1 - Y_2\|_F \quad (5.6)$$

**证明.** <sup>[5]</sup> 设  $Y_1 = U_1 D_1 V_1^\top$ ,  $Y_2 = U_2 D_2 V_2^\top$ , 则  $\bar{Y}_1 = S_\nu(Y_1) = U_1 \bar{D}_1 V_1^\top$ ,  $\bar{Y}_2 = S_\nu(Y_2) = U_2 \bar{D}_2 V_2^\top$ . 其中  $D_i = \text{Diag}(\sigma_i)$ ,  $\bar{D}_i = \text{Diag}(\max\{\sigma_i - \nu, 0\})$ ,  $\sigma_i \in \mathbb{R}^{r_i}$  是  $Y_i$  的奇异值向量,  $r_i = \text{rank } Y_i$ , 记  $\sigma_i$  中大于  $\nu$  的项数为  $k_i$ , 不失一般性, 我们认为奇异值是从大到小排列的, 即  $\sigma_i^{(1)} \geq \dots \geq \sigma_i^{(k_i)} \geq \nu \geq \sigma_i^{(k_i+1)} \geq \dots \geq \sigma_i^{(r_i)} \geq 0$ ,  $i = 1, 2$ .

$$\begin{aligned} & \|Y_1 - Y_2\|_F - \|\bar{Y}_1 - \bar{Y}_2\|_F \\ &= \text{tr}((Y_1 - Y_2)^\top (Y_1 - Y_2)) - \text{tr}((\bar{Y}_1 - \bar{Y}_2)^\top (\bar{Y}_1 - \bar{Y}_2)) \\ &= \text{tr}(Y_1^\top Y_1 + Y_2^\top Y_2 - \bar{Y}_1^\top \bar{Y}_1 - \bar{Y}_2^\top \bar{Y}_2) + 2\text{tr}(Y_1^\top Y_2 - \bar{Y}_1^\top \bar{Y}_2) \\ &= \sum_{i=1}^{r_1} (\sigma_1^{(i)})^2 + \sum_{i=1}^{r_2} (\sigma_2^{(i)})^2 - \sum_{i=1}^{k_1} (\sigma_1^{(i)} - \nu)^2 - \sum_{i=1}^{k_2} (\sigma_2^{(i)} - \nu)^2 - 2\text{tr}(Y_1^\top Y_2 - \bar{Y}_1^\top \bar{Y}_2) \end{aligned}$$

记  $U = U_1^\top U_2$ ,  $V = V_1^\top V_2$ , 将各项展开可得

$$\text{tr}(Y_1^\top Y_2 - \bar{Y}_1^\top \bar{Y}_2) = \text{tr}((D_1 - \bar{D}_1)^\top U (D_2 - \bar{D}_2) V^\top + (D_1 - \bar{D}_1)^\top U \bar{D}_2 V^\top + \bar{D}_1^\top U (D_2 - \bar{D}_2) V^\top) \quad (5.7)$$

有如下的两个定理成立:

- $U$  是正交矩阵,  $\text{tr}(AU)$  取到最大值, 当且仅当  $AU$  是正定矩阵. <sup>[4]</sup>
- 当  $AB$  正定,  $\text{tr}(AB) \leq \sum_i \sigma^{(i)}(A) \sigma^{(i)}(B)$ ,  $\sigma^{(i)}$  是矩阵的第  $i$  个奇异值. <sup>[4]</sup>

不失一般性, 我们设  $r_1 > r_2 > k_1 > k_2$ . 对于(5.7)中等式右边的3项, 由上面的定理, 有

$$\begin{aligned}
tr((D_1 - \bar{D}_1)^\top U(D_2 - \bar{D}_2)V) &\leq \sum_i \sigma^{(i)}(D_1 - \bar{D}_1) \sigma^{(i)}(D_2 - \bar{D}_2) \\
&\leq \sum_{i=1}^{k_2} \nu^2 + \sum_{i=k_2+1}^{k_1} \sigma_2^{(i)} \nu + \sum_{i=k_1+1}^{r_2} \sigma_1^{(i)} \sigma_2^{(i)} \\
&\leq \sum_{i=1}^{k_1} \sigma_2^{(i)} \nu + \sum_{i=k_1+1}^{r_2} \sigma_1^{(i)} \sigma_2^{(i)} \\
tr((D_1 - \bar{D}_1)^\top U \bar{D}_2 V^\top) &\leq \sum_i \sigma^{(i)}(D_1 - \bar{D}_1) \sigma^{(i)}(\bar{D}_2) \\
&\leq \sum_{i=1}^{k_1} (\sigma_2^{(i)} - \nu) \nu + \sum_{i=k_1+1}^{r_2} (\sigma_2^{(i)} - \nu) \sigma_1^{(i)} \\
&\leq \sum_{i=1}^{r_2} (\sigma_2^{(i)} - \nu) \sigma_1^{(i)} \\
tr(\bar{D}_1^\top U(D_2 - \bar{D}_2)V^\top) &\leq \sum_i \sigma^{(i)}(\bar{D}_1) \sigma^{(i)}(D_2 - \bar{D}_2) \\
&\leq \sum_{i=1}^{k_2} (\sigma_1^{(i)} - \nu) \nu + \sum_{i=k_2+1}^{r_2} (\sigma_1^{(i)} - \nu) \sigma_2^{(i)} \\
&\leq \sum_{i=1}^{r_2} (\sigma_1^{(i)} - \nu) \sigma_2^{(i)}
\end{aligned} \tag{5.8}$$

则可得

$$\begin{aligned}
&\|Y_1 - Y_2\|_F - \|\bar{Y}_1 - \bar{Y}_2\|_F \\
&= \sum_{i=1}^{r_1} (\sigma_1^{(i)})^2 + \sum_{i=1}^{r_2} (\sigma_2^{(i)})^2 - \sum_{i=1}^{k_1} (\sigma_1^{(i)} - \nu)^2 - \sum_{i=1}^{k_2} (\sigma_2^{(i)} - \nu)^2 - 2tr(Y_1^\top Y_2 - \bar{Y}_1^\top \bar{Y}_2) \\
&\geq \sum_{i=1}^{r_1} (\sigma_1^{(i)})^2 + \sum_{i=1}^{r_2} (\sigma_2^{(i)})^2 - \sum_{i=1}^{k_1} (\sigma_1^{(i)} - \nu)^2 - \sum_{i=1}^{k_2} (\sigma_2^{(i)} - \nu)^2 \\
&\quad - 2 \left( \sum_{i=1}^{k_1} \sigma_2^{(i)} \nu + \sum_{i=k_1+1}^{r_2} \sigma_1^{(i)} \sigma_2^{(i)} + \sum_{i=1}^{r_2} (\sigma_2^{(i)} - \nu) \sigma_1^{(i)} + \sum_{i=1}^{r_2} (\sigma_1^{(i)} - \nu) \sigma_2^{(i)} \right) \\
&= \sum_{i=k_1+1}^{k_2} \left( 2\sigma_2^{(i)} \nu - \nu^2 + (\sigma_1^{(i)})^2 - 2\sigma_1^{(i)} \sigma_2^{(i)} \right) \\
&\quad + \left( \sum_{i=k_1+1}^{r_2} (\sigma_1^{(i)})^2 + \sum_{i=k_1+1}^{r_1} (\sigma_2^{(i)})^2 - 2 \sum_{i=k_1+1}^{r_1} \sigma_1^{(i)} \sigma_2^{(i)} \right) \\
&\geq \sum_{i=k_1+1}^{k_2} \left( 2\sigma_2^{(i)} \nu - \nu^2 + (\sigma_1^{(i)})^2 - 2\sigma_1^{(i)} \sigma_2^{(i)} \right) + \sum_{i=k_1+1}^{r_2} (\sigma_1^{(i)} - \sigma_2^{(i)})^2 \\
&\geq \sum_{i=k_1+1}^{k_2} \left( 2\sigma_2^{(i)} \nu - \nu^2 + (\sigma_1^{(i)})^2 - 2\sigma_1^{(i)} \sigma_2^{(i)} \right)
\end{aligned} \tag{5.9}$$

当  $k_1 < i \leq k_2$ ,  $\sigma_2^{(i)} < \nu \leq \sigma_1^{(i)}$ , 则

$$2\sigma_2^{(i)} \nu - \nu^2 + (\sigma_1^{(i)})^2 - 2\sigma_1^{(i)} \sigma_2^{(i)} = (\sigma_1^{(i)} - \sigma_2^{(i)})^2 - (\nu - \sigma_2^{(i)})^2 \geq 0$$



那么有  $\|Y_1 - Y_2\|_F - \|\bar{Y}_1 - \bar{Y}_2\|_F \geq \sum_{i=k_1+1}^{k_2} (2\sigma_2^{(i)}\nu - \nu^2 + (\sigma_1^{(i)})^2 - 2\sigma_1^{(i)}\sigma_2^{(i)}) \geq 0$ , 即  $\|Y_1 - Y_2\|_F \geq \|\bar{Y}_1 - \bar{Y}_2\|_F$ .  $\square$

**定理 5.3.** 当  $\mu \in (0, 2/\lambda_{\max}(A^\top A))$ , 其中  $A$  满足  $\mathcal{A}(X) = \text{Avec}(X)$ ,  $h$  是非扩张的, 即

$$\|h(X_1) - h(X_2)\|_F \leq \|X_1 - X_2\|_F \quad (5.10)$$

**证明.** <sup>[5]</sup> 取矩阵  $A$ , 使得  $\mathcal{A}(X) = \text{Avec}(X)$ , 则  $h(X) = X - \mu A^\top (\text{Avec}(X) - b)$ , 则

$$\|h(X_1) - h(X_2)\|_F = \|(I - \mu A^\top A)(\text{vec}(X_1) - \text{vec}(X_2))\|_2 \leq \|I - \mu A^\top A\|_2 \|\text{vec}(X_1) - \text{vec}(X_2)\|_2$$

由  $\mu < 2/\lambda_{\max}(A^\top A)$ ,  $\|I - \mu A^\top A\|_2 < 1$ , 则

$$\|h(X_1) - h(X_2)\|_F \leq \|\text{vec}(X_1) - \text{vec}(X_2)\|_2 \leq \|X_1 - X_2\|_F$$

这证明了  $h$  是非扩张的映射.  $\square$

那么很自然的推论是, 当  $\mu \in (0, 2/\lambda_{\max}(A^\top A))$

$$\|S_{\psi\mu}(h(X_1)) - S_{\psi\mu}(h(X_2))\|_F \leq \|h(X_1) - h(X_2)\|_F \leq \|X_1 - X_2\|_F \quad (5.11)$$

即  $S_{\psi\mu} \circ h$  是一个非扩张的映射, 由Brouwer不动点定理可知, 由任意  $X$  开始进行迭代, 都能收敛到某个不动点.

### 5.3 奇异值计算的近似算法FPCA

实际计算中, 上述迭代过程中, 每步都要求做奇异值分解, 这并不是一件容易的事. 我们认为问题(1.5)中的原矩阵  $X$  是一个低秩矩阵, 那么其奇异值大多都是 0, 故可以考虑只求很少的几个奇异值.

$A \in \mathbb{R}^{p \times q}$ , 取整数  $c, d$ ,  $1 \leq d \leq c \leq q$ ,  $(P_1, \dots, P_q)$ ,  $P_i \geq 0$ ,  $\sum_{i=1}^q P_i = 1$ . 构造随机向量  $(i_1, \dots, i_c)$ ,  $P(i_t = j) = P_j$ ,  $t \in \{1, \dots, c\}$ ,  $j \in \{1, \dots, q\}$ . 再令随机矩阵

$$C = \begin{pmatrix} C^{(1)} \\ \dots \\ C^{(c)} \end{pmatrix} = \begin{pmatrix} A^{(i_1)} / \sqrt{cP_{i_1}} \\ \dots \\ A^{(i_c)} / \sqrt{cP_{i_c}} \end{pmatrix} \in \mathbb{R}^{p \times c} \quad (5.12)$$

求  $C^\top C$  的特征值分解

$$C^\top C = \sum_{i=1}^c \sigma_i^2(C) y_i y_i^\top \quad (5.13)$$

其中  $\sigma_i(C) \geq 0$ , 为  $C$  的奇异值, 再构造矩阵

$$H = \begin{pmatrix} H^{(1)} \\ \dots \\ H^{(d)} \end{pmatrix} = \begin{pmatrix} C y_1 / \sigma_1(C) \\ \dots \\ C y_d / \sigma_d(C) \end{pmatrix} \in \mathbb{R}^{p \times d} \quad (5.14)$$

令

$$A_d = H \text{Diag}(\sigma(C)) (A^\top H \text{Diag}(1/\sigma(C)))^\top \quad (5.15)$$

可以证明  $A_d$  是  $A$  的一个比较好的近似<sup>[2]</sup>

$$\|A - A_d\|_\xi^2 \leq \min_{\text{rank}(D) \leq d} \|A - D\|_\xi^2 + \text{polylog}(d, 1/c) \|A\|_\xi^2 \quad (5.16)$$

其中  $\xi = 2$  或  $F$ ,  $\text{polylog}$  是多重对数函数.

用这种近似的方法改进的FPC算法就是FPCA法, 给出算法

### 算法 3.

- 步1 给出  $X^1$ ,  $\mu^0 > 0$ ,  $1 > \theta > 0$ ,  $\epsilon > 0$ , 设置计数器  $k = 1$ ;
- 步2 若  $\mu^k = \mu^{k-1}\theta \leq \epsilon$ , 则停止;
- 步3 选取合适的  $\psi > 0$ ;
- 步4 计算  $Y^k = X^k - \psi A^*(A(X^k) - b)$ ;
- 步5 选取合适的  $d$ ,  $\{P_i\}$ , 按(5.12)至(5.15), 计算近似的奇异值分解  $Y_d = H \text{Diag}(\sigma(C)) (Y^\top H \text{Diag}(1/\sigma(C)))^\top$
- 步6 计算  $X^{k+1} = S_{\psi\mu^k}(Y_d)$ ;
- 步7  $k = k + 1$ , 转步2.

注 3. 本章除表明引用处, 均为原文<sup>[9]</sup>内容

## 6 结语

在我第一次听说NetFlix大奖赛后, 就对矩阵优化产生了兴趣, 因而选择了这篇文章. 通过本文的阅读, 我比较初步地了解了矩阵完整化问题是什么以及几种常见的算法, 熟悉了矩阵范数, 罚函数, 次梯度等基础知识.

这是第一次精读一篇文献, 也是第一次比较正式地准备报告, 花了比较多时间, 但是在阅读过程中明显感觉自己的提升, 阅读其他参考文献时阻力越来越小. 我也通过这次掌握了许多工具的使用, 比如latex, beamer, Google学术搜索等, 不过同样也因为放了太多精力在latex排版学习等地方, 对文献内容的深入思考不足. 另外最后的报告, 做的也不是那么让自己满意.

本学期的研讨课的学习让我学习到了不少, 还有许多做得不好的地方, 不过总之还是收获颇丰. 最后感谢袁老师和其他各位老师的指导, 以及各位同学的帮助, 谢谢!

## 参考文献

- [1] Emmanuel J Candès and Terence Tao. The power of convex relaxation: Near-optimal matrix completion. *IEEE Transactions on Information Theory*, 56(5):2053–2080, 2010.

- [2] Petros Drineas, Ravi Kannan, and Michael W Mahoney. Fast monte carlo algorithms for matrices ii: Computing a low-rank approximation to a matrix. *SIAM Journal on Computing*, 36(1):158–183, 2006.
- [3] Donald Goldfarb, Shiqian Ma, and Zaiwen Wen. Solving low-rank matrix completion problems efficiently. In *Communication, Control, and Computing, 2009. Allerton 2009. 47th Annual Allerton Conference on*, pages 1013–1020. IEEE, 2009.
- [4] Roger A Horn and Charles R Johnson. *Matrix analysis*. Cambridge university press, 2012.
- [5] Shiqian Ma, Donald Goldfarb, and Lifeng Chen. Fixed point and bregman iterative methods for matrix rank minimization. *Mathematical Programming*, 128(1-2):321–353, 2011.
- [6] Carl D Meyer. *Matrix analysis and applied linear algebra*, volume 2. Siam, 2000.
- [7] Balas Kausik Natarajan. Sparse approximate solutions to linear systems. *SIAM journal on computing*, 24(2):227–234, 1995.
- [8] Benjamin Recht, Maryam Fazel, and Pablo A Parrilo. Guaranteed minimum-rank solutions of linear matrix equations via nuclear norm minimization. *SIAM review*, 52(3):471–501, 2010.
- [9] Robert Schatten. *Norm ideals of completely continuous operators*, volume 27. Springer-Verlag, 2013.
- [10] G Alistair Watson. Characterization of the subdifferential of some matrix norms. *Linear algebra and its applications*, 170:33–45, 1992.
- [11] Zaiwen Wen, Donald Goldfarb, Shiqian Ma, and Katya Scheinberg. Row by row methods for semidefinite programming. *Industrial Engineering*, pages 1–21, 2009.
- [12] 袁亚湘. 非线性优化计算方法. 科学出版社, 2008.