

# 低秩矩阵完整化问题的几种高效解法

林陈冉

2016年12月19日

## 1 简介

### 1.1 什么是低秩矩阵完整化(low-rank matrix completion)

简单来说, 低秩矩阵完整化问题, 就是在仅仅知道矩阵的少部分元素的情况下, 恢复出这个矩阵的所有元素. 这个问题在统计, 图像处理, 计算几何, 机器学习, 信号处理, 模型控制等方面有广泛应用, 比如著名的NetFlix大奖赛问题.

### 1.2 数学模型

显而易见, 补全一个完全随机的矩阵几乎是不可能的, 也是意义不大的. 一般情况下, 我们认为所需要补全的矩阵是有一定规律的, 也就是说, 这个矩阵的秩比较小. 通常我们最感兴趣的是这样的一个问题最优化问题:

$$\begin{aligned} \min \quad & \text{rank}(X) \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \forall (i, j) \in \Omega \end{aligned} \quad (1.1)$$

其中  $X, M \in \mathbb{R}^{p \times q}$ ,  $\Omega$  是已知元素的下标  $(i, j)$  构成的集合,  $|\Omega| = m$ .

在一些情况下, (??)等价于线性约束问题:

$$\begin{aligned} \min \quad & \text{rank}(X) \\ \text{s.t.} \quad & \mathcal{A}(X) = b \end{aligned} \quad (1.2)$$

其中  $b = (b_1, \dots, b_m) \in \mathbb{R}^m$ ,  $\mathcal{A} : \mathbb{R}^{p \times q} \rightarrow \mathbb{R}^m$  是线性算子,  $\mathcal{A}(X) = (\langle A_1, X \rangle, \dots, \langle A_m, X \rangle)$ ,  $A_i \in \mathbb{R}^{p \times q}, \forall i = 1, \dots, m$ ,  $\langle A, X \rangle$  是矩阵内积,

在此给出线性算子  $\mathcal{A}$  的共轭算子的定义:  $\mathcal{A}^* : \mathbb{R}^m \rightarrow \mathbb{R}^{p \times q}$ ,  $\mathcal{A}^*(y) = \sum_{i=1}^m y_i A_i, \forall y = (y_1, \dots, y_m) \in \mathbb{R}^m$ . 容易验证  $\mathcal{A}$  和  $\mathcal{A}^*$  是well-defined, 即

$$\langle \mathcal{A}(X), y \rangle = \langle (\langle A_i, X \rangle), (y_i) \rangle = \sum_{i=1}^m y_i \langle A_i, X \rangle = \langle \sum_{i=1}^m y_i A_i, X \rangle = \langle \mathcal{A}^*(y), X \rangle = \langle X, \mathcal{A}^*(y) \rangle$$

但是(??), (??)都是”NP-难”的, 因此需要一定的转化. 这里我们用核范数来近似矩阵的秩, 把(??)与(??)转化为以下形式:

$$\begin{aligned} \min \quad & \|X\|_* \\ \text{s.t.} \quad & \mathcal{A}(X) = b \end{aligned} \quad (1.3)$$

$$\begin{aligned} \min \quad & \|X\|_* \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \forall (i, j) \in \Omega \end{aligned} \quad (1.4)$$

很自然的, 一个重要的问题是: (??)与(??), 或者(??)与(??)什么时候等价? 略过证明, 直接描述以下重要的结论:

对于(??), Candes和陶哲轩等给出了一个证明. 当在某些条件下, 若已知元素个数  $|\Omega| = m = O(nr \cdot \text{polylog}(n))$ , 其中  $n = \max(p, q)$ ,  $\text{polylog}$  是多重对数函数, 则矩阵有很高概率可以通过(??)恢复.

对于(??), Recht等给出了一个证明. 将线性映射  $\mathcal{A}$  的矩阵形式记作  $A$ , 即  $\mathcal{A}(X) = \text{Avec}(X)$ , 其中  $\text{vec}(X) \in \mathbb{R}^{pq}$  为矩阵  $X$  的向量化. 当  $A$  是一个随机高斯矩阵, 若向量  $b$  的维数  $m \geq C(r(p+q)\log(pq))$ , 其中  $C$  是一个正的常数, 则矩阵有很高概率可以通过(??)恢复.

实际上, 由线性代数知识容易知道, (??)要求的线性约束条件并不总能成立, 因此有时需要适当松弛. 考虑(??)的罚函数:

$$\min \quad \|X\|_* + \frac{1}{2\mu} \|\mathcal{A}(X) - b\|_2^2 \quad (1.5)$$

其中  $\mu$  是某个给定常数.

下面, 将对(??), (??), (??)分别给出一种高效的解法.

## 2 预备知识

此部分会给出一些阅读本文必备的结论, 许多结论将略过证明.

### 2.1 奇异值分解

$\forall X \in \mathbb{R}^{p \times q}$ ,  $X = UDV^\top$ , 其中  $U \in \mathbb{R}^{p \times p}$ ,  $V \in \mathbb{R}^{q \times q}$  是正交矩阵,  $D = \text{Diag}(\sigma) \in \mathbb{R}^{p \times q}$  对角线上为非负实数, 其他位置为0的矩阵.

这个分解称为**奇异值分解(SVD)**, 对角矩阵 $\text{Diag}(\sigma)$ 的每个对角元素  $\sigma_i$  都是非负的, 称为矩阵的**奇异值**, 正交矩阵  $U$  的列向量称为矩阵的**左奇异向量**, 正交矩阵  $V$  的列向量称为矩阵的**右奇异向量**.

有时也认为  $X = UDV^\top$ , 其中  $U \in \mathbb{R}^{p \times r}$ ,  $V \in \mathbb{R}^{q \times r}$  是列正交矩阵,  $D \in \mathbb{R}^{r \times r}$  是非负实对角矩阵,  $r = \text{rank}(X)$ .

## 2.2 罚函数

对于约束优化问题:

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, \quad i = 1, \dots, m_e; \\ & c_i(x) \geq 0, \quad i = m_e + 1, \dots, m \end{aligned} \quad (2.1)$$

我们可以通过把约束条件平方后, 乘上一个很大的常数  $\mu$ , 再加入到目标函数上, 转化为**罚函数**:

$$P(x, \mu) = f(x) + \mu \|\bar{c}(x)\|_2^2 \quad (2.2)$$

其中  $\bar{c}(x) = (\bar{c}_1(x), \dots, \bar{c}_m(x)) \in \mathbb{R}^m$ ,  $\bar{c}_i(x)$  如下定义:  $\bar{c}_i(x) = \begin{cases} c_i(x), & i \leq m_e \\ \max\{0, c_i(x)\}, & i > m_e \end{cases}$ .

当  $\mu \rightarrow \infty$ , (??)和原问题(??)等价.

$$\min_x P(x, \mu) \quad (2.3)$$

但在实际中,  $\mu$  无法取到无穷大, 为了克服这一缺点, 可以定义**增广Lagrange函数**(以下叙述仅考虑等值约束的情况, 即  $m_e = m$ ):

$$P(x, \lambda, \mu) = f(x) - \lambda^\top c(x) + \frac{1}{2}\mu \|c(x)\|_2^2 \quad (2.4)$$

其中  $\lambda, \lambda, \mu, c(x) \in \mathbb{R}^m$  给定.

(??)等价于以下的**Powell罚函数**:

$$P(x, \theta, \mu) = f(x) + \frac{1}{2}\mu \|c(x) - \theta\|_2^2 \quad (2.5)$$

其中  $c(x), \theta \in \mathbb{R}^m$ .

(??)与(??)只相差一个与  $x$  无关的常数  $\frac{1}{2}\mu \|\theta\|_2^2$ .

## 2.3 对偶问题

对于约束优化问题(??),它的Langrange函数为:

$$L(x, \mu, \lambda) = f(x) + \sum_{i=1}^{m_e} \mu_i c_i(x) + \sum_{i=m_e+1}^m \lambda_i c_i(x) \quad (2.6)$$

定义  $g(\mu, \lambda) = \inf_x L(x, \mu, \lambda)$ , 通过这个函数我们可以把(??)转化为它的对偶问题:

$$\begin{aligned} \max_{\mu, \lambda} \quad & g(\mu, \lambda) \\ \text{s.t.} \quad & \mu \succeq 0 \end{aligned} \quad (2.7)$$

当满足一定条件(KKT条件)时, (??)和(??)是等价的.

## 2.4 次梯度

$f: E \rightarrow \mathbb{R}$  是一个定义在  $\mathbb{R}^n$  的凸子集  $E$  上的实值函数,则所有满足

$$f(y) - f(x) \geq u(y - x), \quad \forall y \in E \quad (2.8)$$

的向量  $u$  称为  $f$  在  $x$  点的次梯度, 所有这样的  $u$  构成的集合称为  $f$  在  $x$  点的次梯度集.

次梯度集通常用  $\partial f(x)$  表示

$$\partial f(x) = \{u \in \mathbb{R}^m | f(y) - f(x) \geq u(y - x), \quad \forall y \in E\} \quad (2.9)$$

当函数在  $x$  点可微,  $\partial f(x) = \{f'(x)\}$ ; 当函数在  $x$  点不可微,  $\partial f(x)$  是一个非空的紧凸集.

对于不可微函数或者不可微点, 我们可以采用次梯度替代梯度进行分析. 众所周知, 一个点是最优解的必要条件是该点梯度为0. 相应的,有如下结论:

**定理 2.1.**  $x^*$  是(??)问题的最优解的一个必要条件是:  $0 \in \partial f(x^*)$ . 特别的, 若  $f$  是凸函数, 则是充要条件.

## 2.5 矩阵范数

以下默认  $A \in \mathbb{R}^{m \times n}$ ,  $x \in \mathbb{R}^n$ ,  $k = \max\{m, n\}$ ,  $\lambda(A) = (\lambda_1(A), \dots, \lambda_k(A)) \in \mathbb{R}^k$  是矩阵  $A$  的奇异值向量,  $\lambda_i(A)$  是矩阵  $A$  的第  $i$  个奇异值.

### 2.5.1 诱导-p范数

矩阵的诱导-p范数是将矩阵看作线性算子, 由向量的p-范数诱导而来.

$$\|A\|_p = \sup_{\|x\|_p \leq 1} \|Ax\|_p$$

常见的有**2-范数**:

$$\|A\|_2 = \max_i \lambda_i(A)$$

**1-范数**, 又称**列范数**:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

**$\infty$ -范数**, 又称**行范数**:

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

### 2.5.2 F-范数

矩阵的**F-范数**定义类似于向量的2-范数:

$$\|A\|_F = \left( \sum_{i,j} a_{ij}^2 \right)^{\frac{1}{2}}$$

定义矩阵内积  $\langle A, X \rangle = \text{tr}(A^\top X)$ , F-范数与矩阵内积是相容的, 可以看作内积诱导的范数, 即  $\|A\|_F = \langle A, A \rangle^{\frac{1}{2}}$ .

### 2.5.3 Schatten-p范数

矩阵的**Schatten-p范数**是p-范数应用与矩阵奇异值向量所得的:

$$\|A\|_p = \left( \sum_i \lambda_i(A)^p \right)^{\frac{1}{p}} = \|\lambda(A)\|_p$$

### 2.5.4 核范数

矩阵的**核范数**, 又称**迹范数**, 是在  $p = 1$  时的Schatten-p范数:

$$\|A\|_* = \sum_i \lambda_i(X) = \text{tr}(\sqrt{AA^\top}) = \|A\|_{tr}$$

特别的, 当  $A$  是对称正定的方阵, 则有  $A = \sqrt{AA^\top}$ , 即

$$\|A\|_* = \text{tr}(A)$$

核范数  $\|A\|_* = \|\lambda(A)\|_1$ , 而矩阵的秩  $\text{rank}(A) = \|\lambda(A)\|_0$ , 由此可以看出, 核范数与秩的关系就是1-范数与0-范数的关系, 故采用核范数来近似秩.

核范数是非光滑函数的, 次梯度集如下

$$\partial\|X\|_* = \{UV^\top + W | U^\top W = 0, WV = 0, \|W\|_2 \leq 1\} \quad (2.10)$$

其中  $X = UDV^\top$

### 3 交替方向增广Lagrange法

#### 3.1 问题转化

对于问题(??), 我们考虑它的对偶问题

$$\begin{aligned} \max_{y \in \mathbb{R}^m} \quad & b^\top y \\ \text{s.t.} \quad & \|\mathcal{A}^*(y)\|_2 \leq 1 \end{aligned} \quad (3.1)$$

引入一个形式上的变量  $S$ , 将(??)变为如下的等价形式

$$\begin{aligned} \min_{y \in \mathbb{R}^m} \quad & -b^\top y \\ \text{s.t.} \quad & \mathcal{A}^*(y) - S = 0 \\ & \|S\|_2 \leq 1 \end{aligned} \quad (3.2)$$

可以考虑(??)的增广Lagrange函数

$$L(y, S, X, \mu) = -b^\top y + \langle X, \mathcal{A}^*(y) - S \rangle + \frac{1}{2\mu} \|\mathcal{A}^*(y) - S\|_F^2 \quad (3.3)$$

其中  $X \in \mathbb{R}^{p \times q}$  是某个给定的矩阵(不同于原问题中的  $X$ ),  $\|\cdot\|_F$  是矩阵的  $F$ -范数.

由此我们得到(??)的一个等价问题

$$\begin{aligned} \min_{y, S} \quad & L(y, S, X, \mu) \\ \text{s.t.} \quad & \|S\|_2 \leq 1 \end{aligned} \quad (3.4)$$

通过选取最佳的  $\mu$  和  $X$  可以求出(??)的最优解.

采用如下的迭代过程以求解问题(??)

$$\begin{aligned} \mu^{k+1} &= \alpha \mu^k, \quad \alpha \in (0, 1) \\ X^{k+1} &= X^k + \frac{\mathcal{A}^*(y^{k+1}) - S^{k+1}}{\mu^k} \\ (y^{k+1}, S^{k+1}) &= \arg \min_{y, S} L(y, S, X^k, \mu^k) \end{aligned} \quad (3.5)$$

### 3.2 交替方向求解

但实际上, (??)第3式并不容易解, 因此我们考虑使用交替方向法来求解这个方程, 即

$$y^{k+1} = \arg \min_{y, S} L(y, S^k, X^k, \mu^k) \quad (3.6)$$

$$S^{k+1} = \arg \min_{y, S} L(y^{k+1}, S, X^k, \mu^k) \quad (3.7)$$

**定理 3.1.** 当固定  $S^k$ , (??)的最优解为:

$$y^{k+1} = \mu^k(b - \mathcal{A}(X^k)) + \mathcal{A}(S^k) \quad (3.8)$$

当固定  $y^{k+1}$ , (??)的最优解为:

$$S^{k+1} = U \text{Diag}(\min\{\sigma, 1\}) V^\top \quad (3.9)$$

其中  $U, V$  来自  $Y = \mathcal{A}^*(y^{k+1}) + \mu^k X^k$  的奇异值分解, 即  $Y = U \text{Diag}(\sigma) V^\top$ .

**证明.** 首先来求解(??), 当固定  $S^k$

$$L(y, S^k, X^k, \mu^k) = -b^\top y + \mathcal{A}(X^k)^\top y - \langle X, S^k \rangle + \frac{1}{2\mu^k} \|\mathcal{A}^*(y) - S^k\|_F^2 \quad (3.10)$$

记  $T = \mathcal{A}^*(y) - S^k$ ,  $\mathcal{A}_{ij} = (A_{1_{ij}}, \dots, A_{m_{ij}}) \in \mathbb{R}^m$ , 考虑  $\|T\|_F^2$

$$\|T\|_F^2 = \sum_{i,j} ((\sum_{k=1}^m y_k A_{k_{ij}}) - S_{ij}^k)^2 = \sum_{i,j} (\mathcal{A}_{ij}^\top y - S_{ij}^k)^2$$

则它对 $y$ 的梯度

$$\begin{aligned} & \frac{\partial \|T\|_F^2}{\partial y} \\ &= \frac{\partial \sum_{i,j} (\mathcal{A}_{ij}^\top y - S_{ij}^k)^2}{\partial y} \\ &= \sum_{i,j} \frac{\partial (\mathcal{A}_{ij}^\top y - S_{ij}^k)^2}{\partial y} \\ &= 2 \sum_{i,j} (\mathcal{A}_{ij}^\top y - S_{ij}^k) \mathcal{A}_{ij} \\ &= 2 (\sum_{i,j} T_{ij} A_{k_{ij}}) \\ &= 2 (\langle A_i, T \rangle) \\ &= 2 \mathcal{A}(\mathcal{A}^*(y) - S^k) \end{aligned} \quad (3.11)$$

由此可以给出(??)的梯度

$$\frac{\partial L(y, S^k, X^k, \mu^k)}{\partial y} = -b + \mathcal{A}(X^k) + \frac{1}{\mu^k} \mathcal{A}(\mathcal{A}^*(y) - S^k) \quad (3.12)$$

令(??)式等于0, 可得

$$y^{k+1} = \mu^k(b - \mathcal{A}(X^k)) + \mathcal{A}(S^k) \quad (3.13)$$

再考虑(??). 当固定  $y^{k+1}$

$$\begin{aligned}
 & L(y^{k+1}, S, X^k, \mu^k) \\
 &= -b^\top y^{k+1} + \mathcal{A}(X^k)^\top y^{k+1} - \langle X, S \rangle + \frac{1}{2\mu^k} \|\mathcal{A}^*(y^{k+1})\|^2 - S_F^2 \\
 &= \frac{1}{2\mu^k} (\|S\|_F^2 - 2\langle Y, S \rangle + \|\mathcal{A}^*(y^{k+1})\|_F^2) - b^\top y^{k+1} + \mathcal{A}(X^k)^\top y^{k+1}
 \end{aligned} \tag{3.14}$$

其中  $Y = \mathcal{A}^*(y^{k+1}) + \mu^k X^k$ .

$$\frac{\partial L(y^{k+1}, S, X^k, \mu^k)}{\partial S} = \frac{1}{2\mu^k} \left( \frac{\partial \|S\|_F^2}{\partial S} - 2 \frac{\partial \langle Y, S \rangle}{\partial S} \right) = \frac{S - Y}{\mu^k} \tag{3.15}$$

令(??)式等于0, 则可得  $S^{k+1} = Y$ , 但由约束条件  $\|S\|_2 \leq 1$ , 需对  $Y$  进行修正, 即

$$S^{k+1} = U \text{Diag}(\min\{\sigma, 1\}) V^\top \tag{3.16}$$

其中  $Y = U \text{Diag}(\sigma) V^\top$ . □

根据  $Y$  的定义, 可以简化  $X^{k+1}$  的计算方法

$$X^{k+1} = \frac{\mu^k X^k + \mathcal{A}^*(y^{k+1}) - S^{k+1}}{\mu^k} = \frac{Y - S^{k+1}}{\mu^k} \tag{3.17}$$

重复进行上述迭代,到目标精度停止,下面给出相应算法

#### 算法 1.

- 步1 给出  $\mu^0, X^0, y^0, S^0, \epsilon, \alpha$ , 设置计数器  $k = 0$ ;
- 步2 若  $\frac{\|X^{k+1} - X^k\|_F}{\max\{1, \|X^k\|_F\}} \leq \epsilon$ , 则停止;
- 步3 计算  $y^{k+1} = \mu^k(b - \mathcal{A}(X^k)) + \mathcal{A}(S^k)$ ;
- 步4 计算  $Y = \mathcal{A}^*(y^{k+1}) + \mu^k X^k$ , 并计算其SVD:  $Y = U \text{Diag}(\sigma) V^\top$ ;
- 步5 计算  $S^{k+1} = U \text{Diag}(\min\{\sigma, 1\}) V^\top$ ;
- 步6 计算  $X^{k+1} = \frac{Y - S^{k+1}}{\mu^k}$ ;
- 步7 计算  $\mu^{k+1} = \alpha \mu^k, k = k + 1$ , 转步2.

## 4 RBR法

### 4.1 SDP问题与Schur补

对于问题(??), 我们可以考虑把它转化为一个半定规划(SDP)问题.

一个标准的半定规划问题是

$$\begin{aligned}
 & \min_{X \in S^n} \quad \langle C, X \rangle \\
 & \text{s.t.} \quad \mathcal{A}(X) = b, X \succ 0
 \end{aligned} \tag{4.1}$$

其中  $b \in \mathbb{R}^m$ ,  $\mathcal{A}(X) = (\langle A_1, X \rangle, \dots, \langle A_m, X \rangle)$ ,  $C, A_i \in S^n$ ,  $S^n$  是全体对称矩阵.



对于一个对称正定矩阵  $X \in S^n$  , 我们可以把它写成分块矩阵的形式

$$X = \begin{pmatrix} \xi & y^\top \\ y & B \end{pmatrix} \quad (4.2)$$

其中  $\xi \in \mathbb{R}$  ,  $y \in \mathbb{R}^{n-1}$  ,  $B \in S^{n-1}$  .

容易验证的,  $X$  可以表示为以下形式

$$X = \begin{pmatrix} 1 & y^\top B^{-1} \\ 0 & I \end{pmatrix} \begin{pmatrix} \xi - y^\top B^{-1} y & 0 \\ 0 & B \end{pmatrix} \begin{pmatrix} 1 & 0 \\ B^{-1} y & I \end{pmatrix} \quad (4.3)$$

记  $(X/B) = \xi - y^\top B^{-1} y$  , 称为 $X$ 对于 $B$ 的Schur补.

显然的

$$X \succeq 0 \Leftrightarrow B \succeq 0, (X/B) \geq 0 \quad (4.4)$$

## 4.2 SOCP问题

约定以下记号

$$X_{\alpha, \beta} = \begin{cases} x_{\alpha\beta} & \alpha, \beta \in \mathbb{R} \\ (x_{\alpha\beta_1}, \dots, x_{\alpha\beta_n}) & \alpha \in \mathbb{R}, \beta = \{\beta_1, \dots, \beta_n\} \\ (x_{\alpha_1\beta}, \dots, x_{\alpha_m\beta})^\top & \alpha = \{\alpha_1, \dots, \alpha_m\}, \beta \in \mathbb{R} \\ \begin{pmatrix} x_{\alpha_1\beta_1} & \cdots & x_{\alpha_1\beta_n} \\ \cdots & \cdots & \cdots \\ x_{\alpha_m\beta_1} & \cdots & x_{\alpha_m\beta_n} \end{pmatrix} & \alpha = \{\alpha_1, \dots, \alpha_m\}, \beta = \{\beta_1, \dots, \beta_n\} \end{cases} \quad (4.5)$$

$$i^c = \{1, \dots, n\} \setminus \{i\} = \{1, \dots, i-1, i+1, \dots, n\} \quad (4.6)$$

令  $X = \begin{pmatrix} \xi & y^\top \\ y & B \end{pmatrix} = \begin{pmatrix} X_{i,i} & X_{i,i^c} \\ X_{i^c,i} & X_{i^c,i^c} \end{pmatrix}$  , 等号在相差一个初等变化下成立. 基于(??), 令  $i$  取遍  $\{1, \dots, n\}$  , 逐行解如下的SOCP问题来解决SDP问题(??)

$$\begin{aligned} \min_{[\xi; y] \in \mathbb{R}^n} \quad & \bar{c}^\top \begin{pmatrix} \xi \\ y \end{pmatrix} \\ \text{s.t.} \quad & \bar{X} \begin{pmatrix} \xi \\ y \end{pmatrix} = \bar{b} \\ & (X/B) \geq \delta \end{aligned} \quad (4.7)$$

其中

$$\bar{c} = \begin{pmatrix} C_{i,i} \\ 2C_{i^c,i} \end{pmatrix}, \quad \bar{X} = \begin{pmatrix} X^{(1)}_{i,i} & 2X^{(1)}_{i,i^c} \\ \dots & \dots \\ X^{(m)}_{i,i} & X^{(m)}_{i,i^c} \end{pmatrix}, \quad \bar{b} = \begin{pmatrix} b_1 - \langle X^{(1)}_{i^c,i^c}, B \rangle \\ \dots \\ b_m - \langle X^{(m)}_{i^c,i^c}, B \rangle \end{pmatrix} \quad (4.8)$$

若  $X$  是半正定的, 即  $X \succeq 0$ , 取  $\delta = 0$ ;

若  $X$  是正定的, 即  $X \succ 0$ , 用大于零的数来限制Schur补, 取  $\delta > 0$ .

### 4.3 Powell罚函数

考虑(3.7)的Powell罚函数

$$F(X, \theta, \mu) = \bar{c}^\top \begin{pmatrix} \xi \\ y \end{pmatrix} + \frac{1}{2\mu} \|\bar{X}[\xi; y] - \bar{b} - \theta\|_2^2 \quad (4.9)$$

其中  $\theta \in \mathbb{R}^m$ ,  $\mu > 0$  都是给定的. 记  $\lambda = \theta + \bar{b}$

(??)等价于以下问题

$$\begin{aligned} \min_X \quad & F(X, \lambda, \mu) = \bar{c}^\top \begin{pmatrix} \xi \\ y \end{pmatrix} + \frac{1}{2\mu} \|\bar{X}[\xi; y] - \lambda\|_2^2 \\ \text{s.t.} \quad & X \succeq 0 \end{aligned} \quad (4.10)$$

### 4.4 用SDP和RBR法补全矩阵

回头考虑(??). 当  $X \in S^n$  对称正定, 有  $\|X\|_* = \text{tr}(X)$ , (??)等价于下面的SDP问题

$$\begin{aligned} \min_X \quad & \text{tr}(X) = \langle E, X \rangle \\ \text{s.t.} \quad & X_{ij} = M_{ij}, \quad \forall (i, j) \in \Omega \end{aligned} \quad (4.11)$$

当  $X \in \mathbb{R}^{p \times q}$  不是对称正定的, 可以考虑一个更大的对称正定矩阵  $W$ . 当补全了  $W$ , 则  $X$  自然被补全了(当然, 当  $X$  是对称正定矩阵时, 我们也可以这么做)

$$\begin{aligned} \min_X \quad & \text{tr}(X) \\ \text{s.t.} \quad & X = \begin{pmatrix} X_1 & W \\ W^\top & X_2 \end{pmatrix} \succ 0 \\ & W_{ij} = M_{ij}, \quad \forall (i, j) \in \Omega \end{aligned} \quad (4.12)$$

其中  $X \in S^n$ ,  $n = p + q$ ,  $W_1 \in S^p$ ,  $W_2 \in S^q$ ,  $X, W_1, W_2 \succ \delta$ .

我们主要讨论一般的情况, 即问题(??). 采用RBR法, 对于某个  $i$ , 我们把向量  $y$  分为两个部分, 即

$$y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}, \quad y_1 = X_{\alpha_i, i}, \quad y_2 = X_{\beta_i, i} \quad (4.13)$$

其中  $\alpha_i = \begin{cases} \{j+p | (i, j \in \Omega)\}, i \leq p \\ \{j | (j, i-p) \in \Omega\}, p < i \leq n \end{cases}$ ,  $\beta_i = \{1, \dots, p\} \setminus (\alpha_i \cup \{i\})$ ,  $y_1$  是  $X$  第  $i$  列除去第  $i$  行后所有已知元素构成的列向量,  $y_2$  是  $X$  第  $i$  列除去第  $i$  行后所有未知元素构成的列向量.

$$\begin{aligned} \text{相应的, } B &= \begin{pmatrix} X_{\alpha_i, \alpha_i} & X_{\alpha_i, \beta_i} \\ X_{\beta_i, \alpha_i} & X_{\beta_i, \beta_i} \end{pmatrix}, \quad \xi = X_{i, i}. \text{ 同时, 可以给出 } \bar{X} \begin{pmatrix} \xi \\ y \end{pmatrix}, \lambda \text{ 和 } \bar{c} \text{ 的显式表达} \\ \lambda &= \begin{cases} (M_{i, \alpha_i-p})^\top, & i \leq p \\ M_{\alpha_i, i-p}, & p < i \leq n \end{cases}, \quad \bar{X} \begin{pmatrix} \xi \\ y \end{pmatrix} = y_1, \quad \bar{c} = (1, \overbrace{0, \dots, 0}^{n-1}) \end{aligned} \quad (4.14)$$

故(??)化为以下形式

$$\begin{aligned} \min \quad & \xi + \frac{1}{2\mu} \|y_1 - \lambda\|_2^2 \\ \text{s.t.} \quad & \xi - y^\top B^{-1} y \geq \delta \end{aligned} \quad (4.15)$$

**定理 4.1.** 问题(??)的最优解为

$$\begin{aligned} y_1 &= (2\mu I + X_{\alpha, \alpha})^{-1} X_{\alpha, \alpha} \tilde{b} \\ y_2 &= \frac{1}{2\mu} X_{\beta, \alpha} (\lambda - y_1) \\ \xi &= \frac{1}{2\mu} y_1^\top (\lambda - y_1) + \delta \end{aligned} \quad (4.16)$$

**证明.** 容易发现, 当  $\xi = y^\top B^{-1} y + \delta$  时, 才可能取到最小值, 则(??)等价于

$$\min_y y^\top B^{-1} y + \frac{1}{2\mu} \|y_1 - \lambda\|_2^2 \quad (4.17)$$

令其梯度为0

$$\begin{pmatrix} X_{\alpha, \alpha} & X_{\alpha, \beta} \\ X_{\beta, \alpha} & X_{\beta, \beta} \end{pmatrix}^{-1} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} + \frac{1}{2\mu} \begin{pmatrix} y_1 - \lambda \\ 0 \end{pmatrix} = 0 \quad (4.18)$$

变形可得

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} + \frac{1}{2\mu} \begin{pmatrix} X_{\alpha, \alpha} \\ X_{\beta, \alpha} \end{pmatrix} (y_1 - \lambda) = 0 \quad (4.19)$$

则

$$\begin{aligned} y_1 &= (2\mu I + X_{\alpha, \alpha})^{-1} X_{\alpha, \alpha} \\ y_2 &= \frac{1}{2\mu} X_{\beta, \alpha} (y_1 - \lambda) \end{aligned} \quad (4.20)$$

那么由(??)和(??), 有

$$\xi = y^\top B^{-1}y + \delta = -\frac{1}{2\mu} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}^\top \begin{pmatrix} y_1 - \lambda \\ 0 \end{pmatrix} + \delta = \frac{1}{2\mu} y_1^\top (\lambda - y_1) + \delta \quad (4.21)$$

即 (??)的最优解为(??)

□

我们可以让  $i$  循环取遍  $\{1, \dots, n\}$ , 逐行求解(??), 最终解决问题(??). 给出算法

### 算法 2.

- 步1 给出  $\delta \geq 0$ ,  $X^1 \succ 0$ ,  $F^0 = \text{tr}(X^1)$ ,  $F^1 = +\infty$ ,  $\epsilon > 0$ , 设置计数器  $k = 1$ ,  $i = 1$ ;
- 步2 若  $\frac{|F^{k-1} - F^k|}{\max\{1, |F^{k-1}|\}} \leq \epsilon$ , 则停止;
- 步3 若  $i > n$ , 则令  $i = 1$ ,  $X^{k+1} = X^k$ ,  $k = k + 1$ ,  $F^k = \text{tr}(X^k)$ , 转步2;
- 步4 求出  $i$  对应的  $\alpha_i, \beta_i$ ;
- 步5 若  $|\alpha_i| = 0$ , 令  $X_{\alpha, \alpha}^k = x_{\alpha, \beta}^l = X_{\beta, \alpha}^k = 0$ ,  $X_{\beta, \beta}^k = X^k$ , 否则按通常定义求出以上几个量.
- 步6 按(??), 计算当前最优解  $\xi, y_1, y_2$ , 以及  $y = [y_1, y_2]$ ;
- 步7 令  $X_{i, i}^k = \xi$ ,  $X_{i, i^c}^k = y$ ,  $X_{i^c, i}^k = y^\top$ ;
- 步8  $i = i + 1$ , 转步3;

## 5 FPCA法

### 5.1 FPC法

FPC法是一种基于不动点定理的算法, 可以解决问题(??).

$\|X\|_* + \frac{1}{2\mu} \|\mathcal{A}(X) - b\|_2^2$  是一个凸函数, 求最优解只要求梯度为0的点. 但  $\|X\|_*$  是不可微的, 故考虑次梯度, 即

$$0 \in \mu \partial \|X\|_* + g(X) \quad (5.1)$$

其中  $g(X) = \mathcal{A}^*(\mathcal{A}(X) - b)$

设  $Y = X - \psi g(X)$ ,  $\psi > 0$  是给定常数, 则(??)等价于

$$0 \in \psi \mu \partial \|X\|_* + X - (X - \psi g(X)) = \psi \mu \partial \|X\|_* + X - Y \quad (5.2)$$

(??)恰好是  $\|X\|_* + \frac{1}{2} \|X - Y\|_F^2$  的次梯度, 即(??)等价于

$$\min \psi \mu \|X\|_* + \frac{1}{2} \|X - Y\|_F^2 \quad (5.3)$$

引入矩阵的Shinkage算子, 定义如下

**定义 5.1** (Shinkage算子). 对  $X \in \mathbb{R}^{m \times n}$  做奇异值分解,  $X = U \text{Diag}(\sigma) V^\top$ ,  $r = \text{rank}(X)$ ,  $U \in \mathbb{R}^{m \times r}$ ,  $V \in \mathbb{R}^{n \times r}$ , 对  $\forall \nu > 0$ , 定义向量  $\bar{\sigma} = (\bar{\sigma}_1, \dots, \bar{\sigma}_r)$ , 其中  $\bar{\sigma}_i = \max\{\sigma_i - \nu, 0\}$ , 那么Shinkage算子定义为  $S_\nu(X) = U \text{Diag}(\bar{\sigma}) V^\top$

当认为(??)中的  $Y$  是给定的情况下, 有如下定理

**定理 5.1.** (??)的最优解为  $S_{\psi\mu}(Y)$ , 其中  $S_{\psi\mu}(\cdot)$  是Shinkage算子

**证明.** 不失一般性, 设  $m \leq n$ , 记  $\nu = \psi\mu$ ,  $X = U \text{Diag}(\sigma) V^\top$ ,  $Y = U_Y \text{Diag}(\gamma) V_Y^\top$  是  $X, Y$  的SVD,  $\text{rank} X = r$ ,  $\text{rank} Y = t$ .

因为  $\partial\|X\|_* = \{UV^\top + W | U^\top W = 0, WV = 0, \|W\|_2 \leq 1\}$ , 找到矩阵  $\bar{U} \in \mathbb{R}^{m \times (m-r)}$ ,  $\bar{V} \in \mathbb{R}^{n \times (n-r)}$ , 使得  $\tilde{U} = [U, \bar{U}]$ ,  $\tilde{V} = [V, \bar{V}]$  分别是  $m, n$  阶正交矩阵. 那么易验证, 当  $\bar{\sigma} \in \mathbb{R}_+^{m-r}$ ,  $\|\bar{\sigma}\|_\infty \leq 1$ , 形如  $W = \bar{U}[\text{Diag}(\bar{\sigma}), 0]\bar{V}^\top$  的矩阵  $W \in \partial\|X\|_*$ .

若  $0 \in \nu\partial\|X\|_* + X - Y$ , 则说明  $\exists W \in \partial\|X\|_*$  使  $\nu(UV^\top + W) + X - Y = 0$ . 那么可以看到当  $W = \bar{U}[\text{Diag}(\bar{\sigma}), 0]\bar{V}^\top$ , 则要求

$$\begin{aligned} & \nu(UV^\top + W) + X - Y \\ &= (\nu UIV^\top + \bar{U}[\text{Diag}(\bar{\sigma}), 0]\bar{V}^\top + U \text{Diag}(\sigma) V^\top) - Y \\ &= \begin{pmatrix} U \\ \bar{U} \end{pmatrix} \left[ \begin{pmatrix} \nu I & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 \\ 0 & \nu \text{Diag}(\bar{\sigma}) & 0 \end{pmatrix} + \begin{pmatrix} \text{Diag}(\sigma) & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \right] \begin{pmatrix} V \\ \bar{V} \end{pmatrix}^\top - U_Y \text{Diag}(\gamma) V_Y^\top \\ &= \begin{pmatrix} U \\ \bar{U} \end{pmatrix} \begin{pmatrix} \nu I + \text{Diag}(\sigma) & 0 & 0 \\ 0 & \nu \text{Diag}(\bar{\sigma}) & 0 \end{pmatrix} \begin{pmatrix} V \\ \bar{V} \end{pmatrix}^\top - U_Y \text{Diag}(\gamma) V_Y^\top = 0 \end{aligned} \tag{5.4}$$

当  $\gamma_1 \geq \dots \geq \gamma_t \geq \nu$ , 那我们令  $X = S_\nu(Y)$ , 则  $r = t$ ,  $U = U_Y$ ,  $V = V_Y$ ,  $\sigma = (\gamma_1 - \nu, \dots, \gamma_t - \nu)$ , 对于这样的  $X$ , 取  $\bar{\sigma} = 0$  即  $W = 0$ , (??)成立.

当  $\gamma_1 \geq \dots \geq \gamma_k \geq \nu \geq \gamma_{k+1} \geq \dots \geq \gamma_t$ , 那我们令  $X = S_\nu(Y)$ , 则  $r = k$ ,  $\sigma = (\gamma_1 - \nu, \dots, \gamma_k - \nu, 0, \dots, 0)$ , 对这样的  $X$ , 取  $\bar{\sigma} = (\gamma_{k+1}/\nu, \dots, \gamma_t/\nu, 0, \dots, 0)$ , 同时令  $\bar{U}$  的前  $t - k$  行依次为  $U_Y$  的  $k + 1$  至  $t$  行,  $\bar{V}$  的前  $t - k$  行依次为  $V_Y$  的  $k + 1$  至  $t$  行, 即  $\begin{pmatrix} U \\ \bar{U} \end{pmatrix} = \begin{pmatrix} U_Y \\ \bar{U}' \end{pmatrix}$ ,  $\begin{pmatrix} V \\ \bar{V} \end{pmatrix} = \begin{pmatrix} V_Y \\ \bar{V}' \end{pmatrix}$ , 其中  $\bar{U}'$  是  $\bar{U}$  的后  $m - t$  行,  $\bar{V}'$  是  $\bar{V}$  的后  $n - t$  行, 此时(??)也成立.

故  $S_{\psi\mu}(Y)$  是(??)的解. □

## 5.2 FPC法的收敛性

也就是说, 我们只要求出合适的  $Y$ ,  $S_{\psi\mu}(Y)$  就是(??)的解. 由  $X$  与  $Y$  的关系可以看出, 若  $X^*$  是(??)的解, 则

$$X^* = S_{\psi\mu}(X^* - \mu g(X^*)) = S_{\psi\mu}(X^* - \mu \mathcal{A}^*(\mathcal{A}(X^*) - b)) \quad (5.5)$$

即  $X^*$  是映射  $S_{\psi\mu} \circ h$  的不动点, 其中  $h(X) = X - \mu g(X)$ .

我们有如下的结论

**定理 5.2.** *Shrinkage算子  $S_\nu(\cdot)$  是非扩张的, 即*

$$\|S_\nu(Y_1) - S_\nu(Y_2)\|_F \leq \|Y_1 - Y_2\|_F \quad (5.6)$$

**定理 5.3.** 当  $\mu \in (0, 2/\lambda_{\max}(A^\top A))$ , 其中  $A$  满足  $\mathcal{A}(X) = \text{Avec}(X)$ ,  $h$  是非扩张的, 即

$$\|h(X_1) - h(X_2)\|_F \leq \|X_1 - X_2\|_F \quad (5.7)$$

那么很自然的推论是, 当  $\mu \in (0, 2/\lambda_{\max}(A^\top A))$

$$\|S_{\psi\mu}(h(X_1)) - S_{\psi\mu}(h(X_2))\|_F \leq \|h(X_1) - h(X_2)\|_F \leq \|X_1 - X_2\|_F \quad (5.8)$$

即  $S_{\psi\mu} \circ h$  是一个非扩张的映射, 由Brouwer不动点定理可知, 由任意  $X$  开始进行迭代, 都能收敛到某个不动点.

## 5.3 奇异值计算的近似算法FPCA

实际计算中, 上述迭代过程中, 每步都要求做奇异值分解, 这并不是一件容易的事. 我们认为问题(??)中的原矩阵  $X$  是一个低秩矩阵, 那么其奇异值大多都是 0, 故可以考虑只求很少的几个奇异值.

$A \in \mathbb{R}^{p \times q}$ , 取整数  $c, d, 1 \leq d \leq c \leq q$ ,  $(P_1, \dots, P_q)$ ,  $P_i \geq 0$ ,  $\sum_{i=1}^q P_i = 1$ . 构造随机向量  $(i_1, \dots, i_c)$ ,  $P(i_t = j) = P_j$ ,  $t \in \{1, \dots, c\}$ ,  $j \in \{1, \dots, q\}$ . 再令随机矩阵

$$C = \begin{pmatrix} C^{(1)} \\ \vdots \\ C^{(c)} \end{pmatrix} = \begin{pmatrix} A^{(i_1)} / \sqrt{cP_{i_1}} \\ \vdots \\ A^{(i_c)} / \sqrt{cP_{i_c}} \end{pmatrix} \in \mathbb{R}^{p \times c} \quad (5.9)$$

求  $C^\top C$  的特征值分解

$$C^\top C = \sum_{i=1}^c \sigma_i^2(C) y_i y_i^\top \quad (5.10)$$

其中  $\sigma_i(C) \geq 0$ , 为  $C$  的奇异值, 再构造矩阵

$$H = \begin{pmatrix} H^{(1)} \\ \dots \\ H^{(d)} \end{pmatrix} = \begin{pmatrix} Cy_1/\sigma_1(C) \\ \dots \\ Cy_d/\sigma_d(C) \end{pmatrix} \in \mathbb{R}^{p \times d} \quad (5.11)$$

令

$$A_d = H \text{Diag}(\sigma(C)) (A^\top H \text{Diag}(1/\sigma(C)))^\top \quad (5.12)$$

可以证明  $A_d$  是  $A$  的一个比较好的近似

$$\|A - A_d\|_\xi^2 \leq \min_{\text{rank}(D) \leq d} \|A - D\|_\xi^2 + \text{polylog}(d, 1/c) \|A\|_\xi^2 \quad (5.13)$$

其中  $\xi = 2$  或  $F$ ,  $\text{polylog}$  是多重对数函数.

用这种近似的方法改进的FPC算法就是FPCA法, 给出算法

**算法 3.**

- 步1 给出  $X^1$ ,  $\mu^0 > 0$ ,  $1 > \theta > 0$ ,  $\epsilon > 0$ , 设置计数器  $k = 1$ ;
- 步2 若  $\mu^k = \mu^{k-1}\theta \leq \epsilon$ , 则停止;
- 步3 选取合适的  $\psi > 0$ ;
- 步4 计算  $Y^k = X^k - \psi \mathcal{A}^*(\mathcal{A}(X^k) - b)$ ;
- 步5 选取合适的  $d$ ,  $\{P_i\}$ , 按(??)至(??), 计算近似的奇异值分解  $Y_d = H \text{Diag}(\sigma(C)) (Y^\top H \text{Diag}(1/\sigma(C)))^\top$
- 步6 计算  $X^{k+1} = S_{\psi\mu^k}(Y_d)$ ;
- 步7  $k = k + 1$ , 转步2;